

ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN TỐT NGHIỆP

**Xây dựng hệ thống nhận dạng biểu cảm khuôn mặt
tài xế lái xe, phát hiện cảm xúc tiêu cực, mệt mỏi và
hỗ trợ cảnh báo**

LÊ NGUYỄN MINH ĐỨC

Duc.LNM225611@sis.hust.edu.vn

Chương trình đào tạo: Công nghệ thông tin Việt-Nhật

Giảng viên hướng dẫn: PGS.TS Nguyễn Thị Hoàng Lan

Khoa: Kỹ thuật máy tính

Trường: Công nghệ thông tin và Truyền thông

HÀ NỘI, 06/2022

ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN TỐT NGHIỆP

**Xây dựng hệ thống nhận dạng biểu cảm khuôn mặt
tài xế lái xe, phát hiện cảm xúc tiêu cực, mệt mỏi và
hỗ trợ cảnh báo**

NGUYỄN VĂN A

nguyenvanabc@sis.hust.edu.vn

Chương trình đào tạo: Công nghệ thông tin Việt-Nhật

Giảng viên hướng dẫn: PGS. TS. Phạm Văn ABC

Chữ kí GVHD

Khoa: Kỹ thuật máy tính

Trường: Công nghệ Thông tin và Truyền thông

HÀ NỘI, 06/2022

LỜI CẢM ƠN

Lời cảm ơn của sinh viên (SV) tới người yêu, gia đình, bạn bè, thầy cô, và chính bản thân mình vì đã chăm chỉ và quyết tâm thực hiện ĐATN để đạt kết quả tốt nhất, nên viết phần cảm ơn ngắn gọn, tránh dùng các từ sáo rỗng, giới hạn trong khoảng 100-150 từ.

TÓM TẮT NỘI DUNG ĐỒ ÁN

Sinh viên viết tóm tắt ĐATN của mình trong mục này, với 200 đến 350 từ. Theo trình tự, các nội dung tóm tắt cần có: (i) Giới thiệu vấn đề (tại sao có vấn đề đó, hiện tại được giải quyết chưa, có những hướng tiếp cận nào, các hướng này giải quyết như thế nào, hạn chế là gì), (ii) Hướng tiếp cận sinh viên lựa chọn là gì, vì sao chọn hướng đó, (iii) Tổng quan giải pháp của sinh viên theo hướng tiếp cận đã chọn, và (iv) Đóng góp chính của ĐATN là gì, kết quả đạt được sau cùng là gì. Sinh viên cần viết thành đoạn văn, không được viết ý hoặc gạch đầu dòng.

Sinh viên thực hiện
(Ký và ghi rõ họ tên)

ABSTRACT

Mục này khuyến khích sinh viên viết lại mục “Tóm tắt” đề án tốt nghiệp ở trang trước bằng tiếng Anh. Phần này phải có đầy đủ các nội dung như trong phần tóm tắt bằng tiếng Việt. Sinh viên không nhất thiết phải trình bày mục này.

Nhưng nếu lựa chọn trình bày, sinh viên cần đảm bảo câu từ và ngữ pháp chuẩn tắc, nếu không sẽ có tác dụng ngược, gây phản cảm.

MỤC LỤC

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI.....	1
1.1 Đặt vấn đề và tính cấp thiết của đề tài	1
1.1.1 Rủi ro tai nạn do trạng thái tâm sinh lý của tài xế	1
1.1.2 Tầm quan trọng của việc ứng dụng Trí tuệ nhân tạo (AI) trong giám sát lái xe	1
1.2 Mục tiêu nghiên cứu và phạm vi nghiên cứu.....	2
1.2.1 Mục tiêu.....	2
1.2.2 Đối tượng nghiên cứu	2
1.2.3 Phạm vi nghiên cứu: Luồng dữ liệu video trong cabin xe	2
1.3 Nhiệm vụ đồ án	3
1.4 Định hướng giải pháp.....	4
1.5 Bố cục đồ án	4
CHƯƠNG 2. KHẢO SÁT VÀ PHÂN TÍCH YÊU CẦU.....	6
2.1 Khảo sát hiện trạng và các nghiên cứu liên quan	6
2.1.1 Khảo sát các hệ thống hỗ trợ lái xe an toàn trên thị trường	6
2.1.2 Các nghiên cứu nhận diện ngủ gật và trạng thái cảm xúc tài xế.....	6
2.2 Khảo sát các bộ dữ liệu khuôn mặt phục vụ huấn luyện mô hình	7
2.2.1 Các bộ dữ liệu biểu cảm tổng quát	7
2.2.2 Các bộ dữ liệu chuyên biệt về lái xe	8
2.3 Phân tích yêu cầu chức năng hệ thống.....	8
2.3.1 Yêu cầu của bộ phát hiện biểu cảm khuôn mặt và cảnh báo dùng AI	8
2.3.2 Yêu cầu của Dashboard giám sát và lưu trữ.....	8
2.4 Phân tích yêu cầu phi chức năng đối với mô hình AI	9
2.4.1 Yêu cầu về độ chính xác phân loại của mô hình học sâu.....	9

2.4.2 Yêu cầu về tốc độ xử lý và độ trễ suy luận	9
CHƯƠNG 3. NỀN TẢNG LÝ THUYẾT VÀ CÔNG NGHỆ SỬ DỤNG.....	11
3.1 Tổng quan về mô hình hình học khuôn mặt và các chỉ số sinh học tài xế....	11
3.1.1 Mô hình MediaPipe FaceMesh trích xuất 468 mốc khuôn mặt.....	11
3.1.2 Công thức toán học tính tỷ lệ mở mắt EAR và tỷ lệ mở miệng MAR	11
3.1.3 Chỉ số PERCLOS trong đánh giá rủi ro mệt mỏi	12
3.2 Tìm hiểu về mạng học sâu CNN MobileNetV3.....	13
3.2.1 Kiến trúc MobileNetV3 tối ưu hóa cho thiết bị di động.....	13
3.2.2 Khối Inverted Residuals và khối chú ý Squeeze-and-Excitation	13
3.2.3 Hàm kích hoạt Hard-swish và cơ chế học chuyển giao (Transfer Learning)	14
3.3 Các công nghệ và thư viện phát triển phần mềm	14
3.3.1 Ngôn ngữ Python, framework PyTorch và thư viện OpenCV	14
3.3.2 Thư viện phân tích dữ liệu: Pandas, NumPy, scikit-learn, matplotlib	15
3.3.3 Flask Web Server, Server-Sent Events (SSE) và SQLite.....	15
CHƯƠNG 4. PHÂN TÍCH THIẾT KẾ, TRIỂN KHAI VÀ ĐÁNH GIÁ HỆ THỐNG	16
4.1 Sơ đồ tổng thể hệ thống nhận dạng biểu cảm khuôn mặt tài xế lái xe, phát hiện cảm xúc tiêu cực và cảnh báo	16
4.2 Thiết kế Pipeline xử lý tổng thể của hệ thống	16
4.2.1 Sơ đồ luồng xử lý thời gian thực từ camera hành trình đến bộ cảnh báo tại thiết bị mobile trên xe	16
4.2.2 Luồng xử lý offline các clip video từ camera tại trung tâm (server).	17
4.2.3 Mô tả các giai đoạn luân chuyển và biến đổi dữ liệu	17
4.3 Thiết kế chi tiết các khối xử lý và xây dựng bộ dữ liệu.....	18
4.3.1 Phương pháp tái cấu trúc và gom nhóm dữ liệu để tối ưu hóa khả năng học của mạng.....	18

4.3.2 Thiết kế giải pháp phát hiện và bám sát khuôn mặt.....	18
4.3.3 Thiết kế quy trình tiền xử lý ảnh đầu vào.....	19
4.3.4 Thiết kế các kỹ thuật tăng cường và cân bằng dữ liệu.....	19
4.4 Thiết kế triển khai mô hình học sâu CNN MobileNetV3	20
4.4.1 Thiết kế sơ đồ kiến trúc mạng MobileNetV3 phân loại cảm xúc	20
4.4.2 Thiết kế hàm mất mát và bộ tối ưu hóa.....	21
4.5 Thiết kế chi tiết khối quyết định cảnh báo	21
4.5.1 Thiết kế tập luật logic tích hợp chỉ số hình học và xác suất cảm xúc CNN	21
4.5.2 Thiết kế cơ chế cửa sổ thời gian đảm bảo độ tin cậy cảnh báo.....	22
4.6 Thiết kế kiến trúc phần mềm và cơ sở dữ liệu	22
4.6.1 Thiết kế kiến trúc sơ đồ luồng dữ liệu	22
4.6.2 Thiết kế mô hình dữ liệu quan hệ SQLite	23
4.6.3 Thiết kế giao diện Dashboard giám sát tập trung.....	23
CHƯƠNG 5. CÁC GIẢI PHÁP VÀ ĐÓNG GÓP NỔI BẬT.....	24
5.1 Lập trình và cài đặt ứng dụng.....	24
5.1.1 Xây dựng và cài đặt luồng thu nhận hình ảnh đa luồng và trích xuất đặc trưng	24
5.1.2 Lập trình quá trình huấn luyện mô hình MobileNetV3 trên Py- Torch	24
5.1.3 Cài đặt module logic quyết định cảnh báo và âm thanh cục bộ.....	25
5.1.4 Phát triển Flask Server APIs, database SQLite và giao diện Dash- board	26
5.2 Các giải pháp tối ưu và đóng góp nổi bật về thuật toán (Tối ưu hệ thống)...	26
5.2.1 Thuật toán kết hợp Hybrid (Hình học khuôn mặt & Xác suất cảm xúc CNN).....	26
5.2.2 Bộ lọc làm mượt xác suất cảm xúc.....	27

5.2.3 Cơ chế tự động điều chỉnh ngưỡng động theo đặc trưng sinh học khuôn mặt	27
5.2.4 Thuật toán tự động chấm điểm an toàn	28
5.3 Thử nghiệm và đánh giá chất lượng mô hình	28
5.3.1 Đánh giá độ chính xác trên các tập dữ liệu liên quan.....	28
5.3.2 Biểu diễn kết quả huấn luyện.....	29
5.3.3 Đánh giá độ chính xác qua các chỉ số	29
5.4 Kịch bản thử nghiệm hệ thống và đánh giá hiệu năng	30
CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	31
6.1 Kết luận	31
6.2 Hướng phát triển.....	31
TÀI LIỆU THAM KHẢO.....	35
PHỤ LỤC.....	37
A. HƯỚNG DẪN VIẾT ĐỒ ÁN TỐT NGHIỆP	37
A.1 Ngành học.....	38
A.2 Đánh dấu (bullet) và đánh số (numering)	38
A.3 Cách thêm bảng	39
A.4 Chèn hình ảnh	39
A.5 Tài liệu tham khảo	40
A.6 Cách viết phương trình và công thức toán học.....	40
A.7 Qui cách đóng quyển.....	40
B. ĐẶC TẢ USE CASE.....	42
B.1 Đặc tả use case “Thống kê tình hình mượn sách”	42
B.2 Đặc tả use case “Đăng ký làm thẻ mượn”	42

DANH MỤC HÌNH VẼ

Hình 4.1	Sơ đồ luồng xử lý thời gian thực từ camera hành trình đến bộ cảnh báo	16
Hình A.1	Internet vạn vật	39
Hình A.2	Quy cách đóng quyển đồ án	41
Hình A.3	Quy cách đóng quyển đồ án	41

DANH MỤC BẢNG BIỂU

Bảng 2.1	Khảo sát các bộ dữ liệu khuôn mặt phục vụ huấn luyện mô hình	7
Bảng 5.1	Kết quả đánh giá mô hình MobileNetV3 trên tập kiểm thử . .	29
Bảng A.1	Table to test captions and labels.	39

DANH MỤC THUẬT NGỮ VÀ TỪ VIẾT TẮT

Thuật ngữ	Ý nghĩa
API	Giao diện lập trình ứng dụng (Application Programming Interface)
EUD	Phát triển ứng dụng người dùng cuối(End-User Development)
GWT	Công cụ lập trình Javascript bằng Java của Google (Google Web Toolkit)
HTML	Ngôn ngữ đánh dấu siêu văn bản (HyperText Markup Language)
IaaS	Dịch vụ hạ tầng

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

1.1 Đặt vấn đề và tính cấp thiết của đề tài

Sự bứt phá của ngành giao thông vận tải và mạng lưới logistics toàn cầu đang định hình lại cấu trúc kinh tế của thế giới hiện đại. Sự gia tăng theo cấp số nhân của các đội xe thương mại, dịch vụ gọi xe và phương tiện cá nhân mang lại lợi ích to lớn về lưu thông hàng hóa và con người. Tuy nhiên, đi kèm với sự phát triển này là những thách thức sinh tử liên quan đến an toàn giao thông đường bộ. Trạng thái tâm sinh lý và mức độ nhận thức của người điều khiển phương tiện (tài xế) đóng vai trò trung tâm trong chuỗi nhân quả dẫn đến các thảm kịch trên cao tốc và đường đô thị. Những sự cố này hiếm khi xuất phát từ lỗi cơ khí thuần túy, mà phần lớn bắt nguồn từ sự suy giảm nhận thức thoáng qua hoặc những phản ứng cảm xúc cực đoan vượt tầm kiểm soát của con người.

Thực tiễn này đòi hỏi một sự chuyển dịch mô hình (paradigm shift) từ các biện pháp an toàn thụ động sang các hệ thống an toàn chủ động có khả năng nhận thức ngữ cảnh. Việc ứng dụng Trí tuệ nhân tạo (AI) và Thị giác máy tính (Computer Vision) vào không gian cabin xe không chỉ là một giải pháp công nghệ đơn thuần mà đã trở thành một yêu cầu mang tính chiến lược, được định hướng bởi quy luật cung cầu của thị trường lẫn các khung pháp lý quốc tế khắt khe.

1.1.1 Rủi ro tai nạn do trạng thái tâm sinh lý của tài xế

Để thấu hiểu tính cấp thiết của công nghệ giám sát, việc mổ xẻ nguyên nhân gốc rễ của tai nạn giao thông dưới góc độ dữ liệu dịch tễ học và tâm lý học hành vi là vô cùng quan trọng. Theo thống kê của Tổ chức Y tế Thế giới (WHO), tai nạn giao thông đường bộ tước đi sinh mạng của xấp xỉ 1,3 triệu người mỗi năm, đồng thời là nguyên nhân tử vong hàng đầu đối với thanh thiếu niên và người trưởng thành trẻ tuổi (từ 5 đến 29 tuổi) trên toàn cầu. Một tỷ lệ lớn các vụ tai nạn nghiêm trọng này có nguyên nhân trực tiếp từ trạng thái tâm sinh lý không ổn định của người điều khiển phương tiện. Các yếu tố rủi ro cốt lõi bao gồm:

1. Trạng thái buồn ngủ và mệt mỏi thể chất (Fatigue/Drowsiness):

Việc vận hành phương tiện liên tục trong nhiều giờ, đặc biệt vào ban đêm, rạng sáng, hoặc trên các tuyến đường cao tốc đơn điệu, dễ dẫn đến hiện tượng suy giảm nhận thức cấp tính. Các nghiên cứu đánh giá rủi ro toàn cầu chỉ ra rằng tình trạng buồn ngủ khi lái xe đóng góp từ 3% đến hơn 30% tổng số các vụ tai nạn giao thông. Sự xao nhãng này thường liên quan đến tình trạng thiếu ngủ kéo dài, làm gián đoạn nhịp sinh học (circadian misalignment), đặc biệt phổ biến ở các tài xế có xu hướng hoạt động vào buổi sáng (morning chronotype)

nhưng buộc phải làm việc vào chiều muộn hoặc đêm khuya. Đáng chú ý, hơn 20% tài xế thừa nhận từng cảm thấy cần phải dừng xe khẩn cấp ít nhất một lần do không thể cưỡng lại cơn buồn ngủ.

Biểu hiện nguy hiểm nhất của trạng thái này là sự xuất hiện của các cơn ngủ gật ngắn (microsleep). Đây là các chu kỳ mất ý thức tạm thời kéo dài chỉ từ 1 đến 3 giây. Ở vận tốc 100 km/h, một phương tiện trong 2 giây mất ý thức có thể di chuyển vô định xấp xỉ 55 mét. Trong khoảng thời gian mù này, phương tiện có thể đi lệch làn đường hoặc lao thẳng vào chướng ngại vật. Tai nạn do mệt mỏi và buồn ngủ có khả năng gây ra chấn thương nghiêm trọng và tỷ lệ tử vong cao hơn hẳn các loại tai nạn khác, do người lái xe không có bất kỳ hành động phanh hay đánh lái phòng tránh nào trước khoảnh khắc va chạm.

Tại Hoa Kỳ, Cục Quản lý An toàn Giao thông Đường bộ Quốc gia (NHTSA) ước tính rằng lái xe buồn ngủ là nguyên nhân trực tiếp của hơn 100.000 vụ tai nạn mỗi năm, dẫn đến khoảng 1.550 ca tử vong, 71.000 người bị thương, và thiệt hại kinh tế lên tới 12,5 tỷ USD. Các tổ chức khác như CDC cho rằng con số thực tế còn tồi tệ hơn, ước tính có tới 5.000 đến 6.000 vụ tai nạn chết người mỗi năm có yếu tố mệt mỏi. Từ góc độ tổn thất vĩ mô, các vụ va chạm do lái xe buồn ngủ chiếm khoảng 13% tổng chi phí xã hội khổng lồ trị giá 836 tỷ USD do tai nạn giao thông gây ra tại Mỹ. Tại các quốc gia đang phát triển, con số này cũng ở mức báo động. Các nghiên cứu tại Iran cho thấy mệt mỏi chiếm từ 20% đến 40% nguyên nhân tai nạn. Tại Việt Nam, dữ liệu từ Ủy ban An toàn giao thông Quốc gia cho thấy các vụ tai nạn liên quan đến giấc ngủ chiếm tới 30% tổng số các vụ tai nạn giao thông trong một năm. Một nghiên cứu khác ở vùng nông thôn Ấn Độ cũng chỉ ra rằng 37,6% tài xế gặp nạn đã không có chế độ nghỉ ngơi đầy đủ trước khi lên xe.

2. Trạng thái ức chế tâm lý và cảm xúc tiêu cực (Anger/Fear):

Song song với trạng thái mệt mỏi, các cảm xúc cực đoan như tức giận hoặc hoảng sợ là nguồn cơn của hành vi lái xe hung hăng. Sự căng thẳng khi gặp tắc đường, áp lực thời gian giao hàng, hoặc hành vi ứng xử thiếu văn hóa của các phương tiện xung quanh dễ kích động trạng thái tức giận khi tham gia giao thông (Road Rage). Một người bình thường khi rơi vào trạng thái tâm lý nóng nảy sẽ trải qua sự biến đổi tính cách nhất thời, làm giảm khả năng nhận thức các mối nguy hiểm xung quanh.

Tổ chức AAA Foundation for Traffic Safety báo cáo rằng hành vi lái xe hung hăng chịu trách nhiệm cho hơn 50% tổng số ca tử vong do tai nạn giao thông. Tốc độ cao là hệ quả trực tiếp phổ biến nhất của trạng thái này, đóng vai trò

Bảng 1.1: Chỉ tiêu thống kê tai nạn do mệt mỏi và buồn ngủ (Dữ liệu toàn cầu & khu vực)

Chỉ Tiêu Thống Kê	Số Liệu Ước Tính	Ghi chú/Nguồn Trích Dẫn
Tỷ lệ tai nạn toàn cầu do buồn ngủ	3% - >30%	Tùy thuộc khu vực
Tỷ lệ tai nạn tại Việt Nam do ngủ gật	30%	Ủy ban ATGT Quốc gia
Số vụ tai nạn hàng năm tại Mỹ do buồn ngủ	> 100.000 vụ	NHTSA
Số người chết hàng năm tại Mỹ do buồn ngủ	1.550 - 6.000 ca	NHTSA, CDC
Thiệt hại kinh tế tại Mỹ do lái xe buồn ngủ	12,5 tỷ USD	Ước tính hàng năm
Tỷ lệ chi phí xã hội tại Mỹ	13% tổng chi phí tai nạn (836 tỷ USD)	Tổn thất vĩ mô

là yếu tố góp phần trong gần một phần ba số vụ tai nạn xe hơi chết người. Các hành vi điển hình của Road Rage bao gồm: bám đuôi (tailgating) ở khoảng cách không an toàn, lạng lách, chuyển làn liên tục, vượt đèn đỏ, và la mắng phương tiện khác. Cảm xúc chi phối trực tiếp đến hành vi, khả năng phán đoán và thời gian phản ứng của tài xế. Do đó, việc không kiểm soát được cảm xúc tiêu cực không chỉ trực tiếp đe dọa an toàn sinh mạng của bản thân người lái mà còn biến phương tiện thành một cỗ máy gây sát thương vô định đối với cộng đồng.

1.1.2 Tầm quan trọng của việc ứng dụng Trí tuệ nhân tạo (AI) trong giám sát lái xe

Sự cấp thiết phải giải quyết những thách thức do yếu tố con người gây ra đã biến Hệ thống giám sát người lái (Driver Monitoring System - DMS) từ một tính năng thử nghiệm thành một trang bị an toàn mang tính bắt buộc. Trước đây, các giải pháp giám sát tài xế thường dựa vào các phương pháp tiếp cận thụ động hoặc can thiệp vật lý. Điển hình như các cảm biến đo nồng độ cồn qua hơi thở, thiết bị đeo thông minh đo nhịp tim, hoặc các công nghệ Cảnh báo lệch làn (Lane Departure Warning) và đánh giá biến thiên góc vô lăng thuộc nhóm Hỗ trợ người lái tiên tiến (ADAS). Mặc dù đơn giản trong việc triển khai, các hệ thống thụ động này sở hữu nhiều lỗ hổng chí mạng: độ trễ cảnh báo lớn, gây khó chịu cho người lái (khi phải đeo thiết bị liên tục), dễ sinh ra cảnh báo giả (false positives), và quan trọng nhất là không thể đánh giá trực tiếp trạng thái tập trung của tài xế ngay tại thời điểm trước khi chiếc xe có dấu hiệu mất kiểm soát cơ học.

Với sự bứt phá của Trí tuệ nhân tạo (AI) và Thị giác máy tính (Computer Vision),

việc ứng dụng các mô hình học sâu (Deep Learning) để phân tích hình ảnh trực tiếp từ camera đặt trong cabin xe (In-cabin Monitoring) đã mở ra một hướng đi mới mang tính cách mạng. Hệ thống DMS hiện đại được vận hành bằng AI có khả năng giải quyết triệt để các hạn chế của công nghệ cũ thông qua ba ưu điểm cốt lõi:

- **Theo dõi không tiếp xúc (Non-intrusive):** Hệ thống chỉ sử dụng một camera RGB hoặc camera hồng ngoại (IR/NIR) phổ thông đặt trên táp-lô, trụ A hoặc gương chiếu hậu để liên tục ghi nhận khuôn mặt tài xế. Môi trường trong khoang lái được số hóa mà không gây bất kỳ cản trở vật lý hay cảm giác khó chịu nào cho người điều khiển phương tiện.
- **Nhận diện đa chiều thời gian thực (Real-time Multi-dimensional Recognition):** Nhờ sức mạnh của các mạng nơ-ron tích chập (CNN) và thuật toán ước lượng mốc hình học khuôn mặt (Face Landmark Detection), hệ thống có thể đồng thời trích xuất các đặc trưng vi mô với độ trễ cực thấp (chỉ vài mili-giây). Nó có khả năng đánh giá mức độ khép mí mắt (PERCLOS), tần suất chớp mắt, biên độ ngáp, hướng nhìn của đồng tử, góc gục đầu, và phân loại sâu các biểu cảm cảm xúc (tức giận, sợ hãi, bình thường) ngay tại thời điểm diễn ra hành vi.
- **Cảnh báo chủ động và Quản trị tập trung:** Hệ thống tự động phân tích và đưa ra tín hiệu beep cảnh báo bằng âm thanh/hình ảnh trực tiếp trong cabin nhằm đánh thức phản xạ của tài xế. Đồng thời, thông qua công nghệ viễn thông (Telematics), dữ liệu về các vi phạm trạng thái được đồng bộ hóa về trung tâm điều hành máy chủ từ xa. Khả năng này giúp các doanh nghiệp vận tải quản lý rủi ro một cách chủ động, can thiệp vào lộ trình trước khi tai nạn xảy ra và tối ưu hóa hệ thống bảo hiểm thương mại.

Động lực từ Khung pháp lý quốc tế và Thị trường:

Tầm quan trọng của AI trong giám sát khoang lái không chỉ dừng lại ở lý thuyết mà đã được luật hóa ở mức độ toàn cầu. Ủy ban Châu Âu (EU) đã ban hành Quy định An toàn Chung (General Safety Regulation - GSR), bắt buộc tất cả các loại phương tiện mới bán ra tại Châu Âu từ tháng 7 năm 2024 phải trang bị hệ thống Cảnh báo Chú ý và Buồn ngủ (DDAW). Tiến xa hơn, từ năm 2026, quy định Cảnh báo Xao nhãng Nâng cao (ADDW) sẽ bắt buộc sử dụng giám sát chủ động (camera quét mắt) thay vì cảm biến vô lăng thụ động. Tương tự, tổ chức đánh giá an toàn xe hơi độc lập Euro NCAP đã vạch ra lộ trình "Vision 2030", trong đó kể từ năm 2026, các hệ thống giám sát người lái (DMS) là yêu cầu tiên quyết để một chiếc xe đạt được điểm an toàn tối đa (5 sao) trong hạng mục Giám sát trạng thái người ngồi (OSM). Các hệ thống này bắt buộc phải giao tiếp được với hệ thống Phanh khẩn cấp

tự động (AEB) để thay đổi mức độ can thiệp khi phát hiện tài xế đang xao nhãng.

Bảng 1.2: Khung pháp lý và tiêu chuẩn quốc tế về hệ thống giám sát người lái

Khung Pháp Lý / Tiêu Chuẩn	Quy Định Cốt Lõi	Lộ Trình Áp Dụng
EU GSR - DDAW	Bắt buộc trang bị hệ thống cảnh báo buồn ngủ và chú ý trên mọi xe thương mại và xe con mới.	07/07/2022 (Xe mẫu mới) - 07/07/2024 (Toàn bộ xe đăng ký mới)
EU GSR - ADDW	Bắt buộc giám sát chủ động bằng camera phân tích tầm nhìn và mắt thay cho cảm biến thụ động.	Bắt đầu từ 2026
Euro NCAP (OSM)	Tích hợp hệ thống DMS đánh giá xao nhãng liên kết trực tiếp với ADAS/AEB để duy trì đánh giá an toàn tối đa.	Lộ trình 2023 - 2026 ("Vision 2030")

Sức ép pháp lý này đã kích hoạt một chu kỳ tăng trưởng bùng nổ cho thị trường DMS. Các báo cáo phân tích tài chính chỉ ra quy mô thị trường DMS toàn cầu ước tính đạt khoảng 3,5 đến 5,2 tỷ USD vào năm 2025, và được dự phóng sẽ bứt phá lên mức 9,5 đến 12,4 tỷ USD vào giai đoạn 2033 - 2036, với tốc độ tăng trưởng kép hàng năm (CAGR) dao động từ 8,1% đến 13,3%. Đặc biệt, các hệ thống dựa trên camera trực quan dự kiến sẽ thống trị thị phần (chiếm trên 43% đến 57%) do độ chính xác cao trong việc theo dõi chuyển động mắt và đầu. Việc tích hợp DMS còn mang lại lợi ích tài chính rõ rệt cho các nhà quản lý đội xe; ví dụ, một đội xe 85 chiếc tại Houston (Mỹ) đã tiết kiệm tới 378.000 USD chi phí bảo hiểm thường niên sau khi triển khai hệ thống telematics giám sát hành vi tài xế.

Từ nền tảng lý thuyết sinh học, động lực thị trường, cho đến sự ép buộc của khung pháp lý quốc tế, việc thực hiện đề tài "**Xây dựng hệ thống nhận dạng biểu cảm khuôn mặt tài xế lái xe, phát hiện cảm xúc tiêu cực, mệt mỏi và hỗ trợ cảnh báo**" là vô cùng cấp thiết. Đề tài không chỉ mang tính thực tiễn cao mà còn là mảnh ghép hoàn hảo để giải quyết triệt để rủi ro từ yếu tố con người, phù hợp với xu hướng chuyển đổi số không thể đảo ngược trong ngành Giao thông thông minh (ITS).

1.2 Mục tiêu nghiên cứu và phạm vi nghiên cứu

Để chuyển hóa các yêu cầu lý thuyết thành một hệ thống phần mềm có khả năng vận hành thực tế trong điều kiện công nghiệp, giới hạn của đề tài cần được xác định một cách khoa học. Môi trường trong khoang lái ô tô áp đặt các giới hạn cực kỳ nghiêm ngặt về nhiệt độ vận hành, không gian vật lý, năng lượng tiêu thụ, và đặc biệt là năng lực tính toán của hệ thống nhúng.

1.2.1 Mục tiêu

Mục tiêu tối thượng của nghiên cứu là thiết kế và xây dựng một giải pháp lai (Hybrid System) kết hợp tối ưu giữa hai trường phái tính toán của Thị giác máy tính: (1) Phân tích các đặc trưng hình học khuôn mặt dựa trên mốc không gian 3D để nhận diện trạng thái buồn ngủ, mất tập trung; và (2) Ứng dụng mô hình mạng học sâu phân loại ảnh tích chập (CNN) để nhận diện các biểu cảm cảm xúc (tức giận, sợ hãi).

Hệ thống hướng tới việc đạt được độ tin cậy cao về mặt nhận diện, đồng thời phải thỏa mãn tiêu chí hoạt động mượt mà, thời gian thực (real-time) trên các thiết bị máy tính biên (Edge Computing Devices) có tài nguyên phần cứng giới hạn (CPU tiêu chuẩn, không phụ thuộc vào các vi mạch xử lý đồ họa GPU đắt tiền). Sự kết hợp này nhằm loại bỏ các cảnh báo giả, tối ưu hóa băng thông truyền tải và xây dựng một quy trình quản trị rủi ro hoàn thiện từ Thiết bị đầu cuối (Client) đến Máy chủ đám mây (Cloud Server).

1.2.2 Đối tượng nghiên cứu

Hệ sinh thái công nghệ cấu thành nên giải pháp DMS đòi hỏi sự tập trung vào các đối tượng nghiên cứu cụ thể, bao gồm kiến trúc mạng nơ-ron, thư viện trích xuất đặc trưng, và nguồn dữ liệu huấn luyện.

1. Các mô hình học sâu phân loại ảnh đa lớp:

Nghiên cứu đặt trọng tâm vào việc đánh giá và tinh chỉnh kiến trúc MobileNetV3 (phiên bản Large). So với các mạng học sâu khổng lồ như VGG19 (tuy đạt độ chính xác lên đến 99,7% trên tập dữ liệu KMU-FED nhưng lại đòi hỏi hàng tỷ phép tính dấu phẩy động FLOPs), MobileNetV3 mang tính đột phá cho môi trường thiết bị di động. Nó tận dụng các khối residual đảo ngược (inverted residual blocks), tích hợp thuật toán tìm kiếm cấu trúc mạng (Network Architecture Search) và cơ chế Attention nhẹ (Squeeze-and-Excitation). Kiến trúc này cho phép suy luận tốc độ cao, giữ được lượng tham số nhỏ mà vẫn đảm bảo độ chính xác vượt trội khi phân loại các lớp cảm xúc phức tạp. Đi kèm với đó, mô hình BlazeFace được nghiên cứu để giải bài toán định vị và bám sát khuôn mặt (Face Detection) trong các điều kiện thiếu sáng hoặc bị che khuất.

2. Các giải pháp trích xuất mốc hình học không gian:

Đối tượng nghiên cứu trọng yếu cho bài toán buồn ngủ là thư viện MediaPipe FaceMesh. Giải pháp này cung cấp khả năng trích xuất ma trận tọa độ không gian 3D của 468 mốc khuôn mặt (landmarks) theo thời gian thực. Từ ma trận tọa độ này, hệ thống có thể tính toán chính xác biên độ mở của mí mắt và khẩu hình miệng thông qua các phương trình hình học Euclid mà không cần qua các

lớp xử lý CNN nặng nề.

3. Tập dữ liệu huấn luyện (Dataset Ecosystem):

Sức mạnh của một thuật toán AI bị chi phối trực tiếp bởi chất lượng và tính đại diện của dữ liệu huấn luyện. Không gian cabin là một môi trường quang học khắc nghiệt: ánh sáng thay đổi liên tục (đi vào hầm chui, ngược nắng, ban đêm), các che khuất vật lý (kính râm, khẩu trang), và sự đa dạng chủng tộc của tài xế. Do đó, nghiên cứu khảo sát và tái cấu trúc một hệ sinh thái dữ liệu bao gồm các bộ dữ liệu khuôn mặt tổng quát và các bộ dữ liệu chuyên biệt cho môi trường khoang lái ô tô:

- **Các tập dữ liệu về trạng thái buồn ngủ/xao nhãng:**

NTHU-DDD (National Tsing Hua University Drowsy Driver Detection):

Chứa 9,5 giờ video phân mảnh từ 18 đối tượng, đánh nhãn các trạng thái buồn ngủ, ngáp và mất tập trung trong bối cảnh phòng thí nghiệm giả lập.

UTA-RLDD (Real-Life Drowsiness Dataset): Ghi lại quá trình chuyển giao nhận thức tự nhiên của tài xế từ trạng thái tỉnh táo sang một mức nhẹ và cuối cùng là ngủ gật cực độ. Tập dữ liệu được phân chia theo các cửa sổ thời gian 30 giây để phục vụ phân tích chuỗi trạng thái liên tục.

- **Các tập dữ liệu về cảm xúc và đặc điểm chiếu sáng:**

MLI-DER (Multiple Light Intensities Driver Emotion Recognition): Một cơ sở dữ liệu đột phá chuyên giải quyết bài toán nhiễu sáng (Illumination invariance). Tập dữ liệu cung cấp các hình ảnh khuôn mặt tài xế dưới nhiều cường độ sáng phức tạp, giúp mô hình bóc tách đặc trưng cảm xúc khỏi yếu tố ngoại cảnh.

KMU-FED (Keimyung University Facial Expression of Drivers): Cung cấp các chuỗi hình ảnh thực tế thu bằng camera cận hồng ngoại (NIR) gắn trên vô lăng/táp-lô từ 12 đối tượng lái xe thực tế. Bộ dữ liệu này có ý nghĩa quan trọng trong việc huấn luyện mô hình vượt qua các rào cản về bóng đổ hình học và sự che khuất do kính phân cực hay góc quay chéo.

Ngoài ra, các tập dữ liệu biểu cảm đại chúng như RAF-DB, AffectNet, FER-2013, KDEF và SFEW được nghiên cứu sử dụng làm trọng số cơ sở (baseline weights) để áp dụng kỹ thuật Học chuyển giao (Transfer Learning) trước khi tinh chỉnh riêng cho không gian cabin.

1.2.3 Phạm vi nghiên cứu: Luồng dữ liệu video trong cabin xe

Để đảm bảo tính khả thi và tập trung sâu vào giải quyết cốt lõi bài toán, phạm vi nghiên cứu được khoanh vùng ở các khía cạnh không gian, chức năng và phần cứng như sau:

- **Vị trí thu nhận tín hiệu:** Hệ thống chỉ xử lý luồng dữ liệu video trực tiếp thu nhận từ góc nhìn trực diện phía trước tài xế. Môi trường giả lập tương đương với việc bố trí một camera hành trình hoặc webcam đặt tại khu vực gương chiếu hậu trung tâm hoặc trên bảng điều khiển táp-lô (dashboard), mô phỏng góc nhìn quang học bao quát phần đầu và vai của tài xế.
- **Phạm vi nhận dạng và phân loại:**
 - **Nhóm 1:** Nhận dạng trạng thái thể chất suy giảm bao gồm mệt mỏi, buồn ngủ (Fatigue/Drowsiness) và hành vi xao nhãng hướng nhìn (Distracted) dẫn đến mất tập trung trên đường.
 - **Nhóm 2:** Phân loại 5 lớp cảm xúc cốt lõi có tác động trực tiếp đến động năng lái xe, bao gồm: trạng thái Bình thường (Neutral - baseline), Tức giận (Anger - nguyên nhân Road Rage), Sợ hãi (Fear - khủng hoảng tâm lý), Vui vẻ (Happiness) và Buồn bã (Sadness).
- **Giới hạn nền tảng phần cứng:** Việc thiết kế mô hình bắt buộc phải tối ưu hóa để thực thi quá trình suy luận (Inference) thời gian thực trên các bộ vi xử lý trung tâm (CPU) thông thường. Hệ thống không yêu cầu thiết bị xử lý phải có card đồ họa chuyên dụng (GPU cao cấp) ở phía Client. Giới hạn này đảm bảo tính khả thi cao nhất khi triển khai hàng loạt dự án ra thực tế trên các hộp đen viễn thông (Telematics Box) hoặc thiết bị máy tính biên giá rẻ như Raspberry Pi gắn trên hàng triệu phương tiện thương mại.

1.3 Nhiệm vụ đề án

Để giải quyết triệt để bài toán an toàn giao thông nêu trên và hoàn thành các mục tiêu khoa học, đề án xác định rõ 5 nhiệm vụ thực thi cụ thể với độ chi tiết cao:

1. Nghiên cứu lý thuyết và cơ sở toán học sinh trắc:

Nhiệm vụ đầu tiên là tìm hiểu sâu về nền tảng cơ sinh học và phương pháp số hóa chuyển động khuôn mặt. Tập trung nghiên cứu công thức toán học tính toán các chỉ số vi mô như EAR (Eye Aspect Ratio) để đánh giá biên độ mở của nhãn cầu, và MAR (Mouth Aspect Ratio) để đo lường động học của việc ngáp. Về mặt lý thuyết, EAR được tính toán bằng tỷ lệ khoảng cách dọc và ngang giữa các mốc điểm quanh mắt. Mức EAR bình thường duy trì trên 0.20, và sụt giảm về gần 0 khi nhắm mắt. Hệ thống cần phát hiện các khoảnh khắc EAR rơi xuống dưới ngưỡng cảnh báo (ví dụ 0.15 hoặc 0.20). Tương tự, MAR > 0.60 thường được sử dụng làm mốc xác định một hành vi ngáp. Hơn thế nữa, nghiên cứu mở rộng sang các chỉ số vĩ mô như góc nghiêng trục đầu (Pitch) và tiêu chuẩn PERCLOS (Percentage of Eyelid Closure). PERCLOS đánh giá

tỷ lệ phần trăm thời gian mí mắt nhắm vượt quá 80% trong một chu kỳ thời gian nhất định (ví dụ 1 phút), được y khoa công nhận là chỉ báo độ tin cậy cao nhất cho mức độ kiệt sức. Đồng thời, đi sâu vào lý thuyết kiến trúc mạng CNN tối ưu dành cho thiết bị di động MobileNetV3 để chứng minh sự vượt trội về thông lượng xử lý.

2. Xây dựng và chuẩn hóa bộ dữ liệu tích hợp:

Thực hiện quá trình thu thập, tiền xử lý và đồng nhất hóa cấu trúc dữ liệu từ các bộ dữ liệu khuôn mặt và trạng thái lái xe rời rạc trên thế giới (như RAF-DB, NTHU DDD, UTA-RLDD, MLI-DER, KMU-FED). Nhiệm vụ này yêu cầu xây dựng các kịch bản ánh xạ nhãn (label mapping), loại bỏ các dữ liệu nhiễu, cân bằng số lượng mẫu giữa các lớp cảm xúc, và tái cấu trúc chúng thành một tập dữ liệu chuẩn DMS duy nhất phục vụ vòng đời huấn luyện mô hình.

3. Huấn luyện mô hình trí tuệ nhân tạo:

Lập trình quy trình tiền xử lý hình ảnh nâng cao nhằm chống lại các biến động môi trường. Kỹ thuật cân bằng lược đồ mức xám cục bộ CLAHE (Contrast Limited Adaptive Histogram Equalization) được áp dụng để khôi phục chi tiết vùng tối. Kết hợp với kỹ thuật cắt cúp khuôn mặt tự động (Face Cropping) để tập trung ma trận ảnh vào vùng chứa đặc trưng. Tiếp theo, thiết lập môi trường bằng framework PyTorch, định nghĩa hàm mất mát (Loss Function), bộ tối ưu hóa (Optimizer) và thực thi quá trình huấn luyện mô hình MobileNetV3. Các siêu tham số (hyperparameters) được tinh chỉnh lặp lại để đạt điểm cân bằng giữa độ chính xác dự đoán (Accuracy) và tránh hiện tượng học vẹt (Overfitting).

4. Xây dựng chương trình phần mềm thực nghiệm Edge-to-Cloud:

Nhiệm vụ trọng tâm là hiện thực hóa thuật toán thành một hệ thống phần mềm hoàn chỉnh, được chia làm hai phân hệ tương tác hai chiều:

- **Phía Client (AI Biên):** Lập trình module đọc luồng video từ camera sử dụng kỹ thuật xử lý đa luồng (multi-threading) để tránh nghẽn bộ đệm. Tích hợp engine suy luận AI, kết hợp các bộ lọc tín hiệu thời gian thực nhằm khử nhiễu dữ liệu. Khi phát hiện vi phạm, phần mềm lập tức kích hoạt các module phát âm thanh (beep) cảnh báo cục bộ tới người lái.
- **Phía Server (Trung tâm):** Thiết lập một máy chủ ứng dụng web (Web Server) tối giản và hiệu suất cao bằng framework Flask. Xây dựng các cổng giao tiếp API (RESTful APIs) để lắng nghe và thu nhận thông tin viễn thông. Dữ liệu được cấu trúc và lưu trữ vĩnh viễn vào hệ quản trị cơ sở dữ liệu SQLite. Phát triển cơ chế đồng bộ hóa dữ liệu từ máy chủ đẩy thẳng lên giao diện điều hành (Dashboard) trên trình duyệt web thông qua

luồng kết nối liên tục Server-Sent Events (SSE).

5. Thử nghiệm thực địa và đánh giá hệ thống:

Triển khai phần mềm lên các cấu hình phần cứng thử nghiệm để đánh giá toàn diện. Các tiêu chí đánh giá không chỉ dừng ở độ chính xác phân loại của mô hình học sâu (Precision, Recall, F1-Score) trên tập kiểm thử tĩnh, mà còn đo lường hiệu năng kỹ thuật của hệ thống trên luồng camera động thời gian thực. Các thông số như Tốc độ xử lý khung hình trên giây (FPS), mức tiêu hao năng lượng CPU, và độ trễ truyền tin được ghi nhận. Đồng thời, phân tích sâu các kịch bản lỗi ở vùng biên (edge cases) như tài xế xoay mặt quá góc độ cho phép hoặc thay đổi cường độ sáng đột ngột, từ đó đề xuất phương án tinh chỉnh cho các phiên bản sau.

1.4 Định hướng giải pháp

Hệ thống DMS được định hướng thiết kế theo mô hình kiến trúc lai phân tán Edge-to-Cloud, phản ánh xu thế hiện đại trong thiết kế các hệ thống Internet vạn vật (IoT). Mô hình này giải quyết triệt để vấn đề nghẽn cổ chai mạng bằng cách đẩy năng lực xử lý tính toán ra sát với nguồn sinh dữ liệu (biên), và chỉ sử dụng mạng viễn thông (4G/5G) để truyền tải các tín hiệu siêu dữ liệu (metadata) mang tính quyết định. Hệ thống được cấu thành từ hai phân hệ độc lập nhưng liên kết chặt chẽ:

1. Phân hệ AI Biên (Edge Client) và Thuật toán tối ưu tính toán:

Phân hệ phía khách (Client) bao gồm một webcam tiêu chuẩn kết nối trực tiếp với thiết bị máy tính nhúng (hoặc laptop giả lập) gắn bên trong xe. Khác với các hệ thống phụ thuộc đám mây, toàn bộ phân hệ này chạy mã nguồn Python biên dịch tại chỗ, sử dụng cơ chế xử lý đa luồng (Multi-threading). Cơ chế này tách biệt quá trình đọc ảnh (I/O bounds) và quá trình xử lý AI (CPU bounds), đảm bảo khung hình camera luôn được bắt giữ liên tục mà không gặp hiện tượng giật lag hay trễ hình.

Để giải quyết bài toán giới hạn tài nguyên CPU, giải pháp ứng dụng thiết kế xử lý bất đối xứng theo chu kỳ, gọi là Bỏ qua khung hình (Skip-frame). Việc trích xuất các mốc 3D và tính toán EAR/MAR bằng MediaPipe vốn cực kỳ nhẹ bèn, do đó sẽ được thực thi trên mọi khung hình (toàn thời gian). Tuy nhiên, mạng CNN học sâu MobileNetV3 (phục vụ việc phân loại 5 trạng thái cảm xúc phức tạp) lại tiêu thụ nhiều nhiệt năng tính toán. Do trạng thái cảm xúc của con người hiếm khi biến đổi hoàn toàn trong khoảng thời gian dưới 1 giây, hệ thống được thiết lập để chỉ chạy suy luận CNN ngắt quãng (ví dụ: chỉ chạy 1 lần sau mỗi 5 hoặc 10 khung hình). Kỹ thuật này giữ cho tốc độ FPS tổng thể luôn ở mức cao mà vẫn bảo toàn tính liên tục của việc nhận thức ngữ cảnh

hành vi.

Khi thuật toán tại Client phát hiện chỉ số EAR, MAR hoặc cảm xúc vi phạm ngưỡng an toàn đã cấu hình, phần mềm sẽ không lập tức phát tín hiệu đi. Đây là lúc logic cốt lõi tiếp theo tham gia định hướng giải pháp: Bộ lọc Đảo nhiễu (Debounce Logic). Trong thực tế đo lường tín hiệu chuỗi thời gian, các giá trị thường dao động hỗn loạn ở sát vạch ngưỡng. Một cái chớp mắt thông thường hay một cái tắc lưỡi có thể khiến EAR/MAR chạm ngưỡng trong 1-2 khung hình. Nếu không có bộ lọc, hệ thống sẽ kích hoạt vô số cảnh báo giả, gây ra hội chứng "mệt mỏi vì cảnh báo" (alert fatigue) cho tài xế và làm tràn bộ đệm cơ sở dữ liệu. Cơ chế Debounce xử lý vấn đề này bằng cách áp dụng một cửa sổ thời gian chờ (delay window) khoảng từ 800 mili-giây đến 1 giây. Khi phát hiện một lỗi vượt ngưỡng (ví dụ MAR chỉ ra trạng thái "Ngáp"), hệ thống khởi động bộ đếm thời gian. Nếu trạng thái "Ngáp" không được duy trì liên tục và biến mất trước khi hết khoảng thời gian $T_{debounce}$, nó bị phân loại là nhiễu và bị triệt tiêu. Chỉ khi tín hiệu ổn định vượt quá bộ đếm thời gian, sự kiện mới chính thức được ghi nhận. Lúc này, Client sẽ xuất ra tín hiệu âm thanh Beep cảnh báo cục bộ qua hệ thống loa xe, đồng thời đóng gói dữ liệu cấu trúc dạng JSON và thực hiện một lệnh gọi POST lên Server.

2. Phân hệ Quản trị Trung tâm (Cloud Server) và Đồng bộ hóa thời gian thực:

Tại trung tâm điều hành, máy chủ đám mây triển khai nền tảng Web Server tối giản bằng Flask. Nhiệm vụ của máy chủ là lắng nghe các yêu cầu POST liên tục cập nhật trạng thái từ hàng ngàn phương tiện gửi về. Nhờ cơ chế Debounce tại Client đã lọc sạch nhiễu, lượng dữ liệu đổ về Server là các chuỗi cảnh báo đặc và có giá trị cao, giúp giảm thiểu đáng kể xung đột ghi vào hệ quản trị cơ sở dữ liệu quan hệ cục bộ SQLite. SQLite được chọn nhờ tính bảo mật cao, khả năng lưu trữ tệp tin vĩnh viễn không cần cấu hình phức tạp, hoàn toàn đáp ứng được quy mô dữ liệu của các đội xe tầm trung.

Định hướng giải pháp cho giao diện người dùng (Dashboard) là triệt tiêu hoàn toàn độ trễ hiển thị. Thay vì yêu cầu trình duyệt của người quản lý phải liên tục tải lại trang (polling - một giải pháp cổ điển gây quá tải máy chủ), hệ thống thiết lập một luồng Server-Sent Events (SSE). Phương thức luồng một chiều (unidirectional stream) này duy trì một đường ống kết nối HTTP mở vĩnh viễn giữa Server và Client Web. Ngay tại thời điểm cơ sở dữ liệu SQLite ghi nhận một sự kiện tai nạn hoặc biểu cảm tức giận (Anger) từ bất kỳ xe nào, máy chủ lập tức đẩy (push) gói cập nhật đó xuống thẳng trình duyệt. Giao diện frontend sẽ thu nhận gói tin và tái hiện tức thời danh sách phương tiện vi phạm, cập nhật

đồ thị Chart.js và tính toán lại điểm số rủi ro của tài xế. Nhờ đó, doanh nghiệp vận tải sở hữu một tháp không lưu viễn thông thực thụ, trao quyền can thiệp vào lộ trình của tài xế trước khi những biểu hiện tâm lý và thể chất kia chuyển hóa thành các tai nạn thảm khốc.

1.5 Bố cục đề án

Dựa trên các mục tiêu và định hướng giải pháp đã thiết lập, cấu trúc của báo cáo đề án tốt nghiệp được chia nhỏ và hệ thống hóa thành 6 chương chuyên sâu. Mỗi chương đóng vai trò giải quyết một khía cạnh riêng biệt từ nền tảng lý thuyết cho đến thực thi kỹ thuật, đảm bảo tính liên mạch của một công trình nghiên cứu khoa học:

- **Chương 1. Giới thiệu đề tài:** Cung cấp bức tranh toàn cảnh về vấn đề nghiên cứu. Trình bày các dữ liệu dịch tễ học và luật pháp để làm nổi bật lý do chọn đề tài và tính cấp thiết. Định hình rõ mục tiêu, đối tượng, phạm vi nghiên cứu (giới hạn ở luồng video cabin, tập trung mô hình MobileNetV3) và phác thảo định hướng kiến trúc giải pháp Edge-to-Cloud.
- **Chương 2. Khảo sát và phân tích yêu cầu hệ thống:** Đi sâu vào phân tích hệ sinh thái công nghệ hiện hữu. Khảo sát chi tiết tính chất của các bộ dữ liệu khuôn mặt dùng để huấn luyện (đặc biệt là NTHU DDD, UTA-RLDD, MLI-DER và KMU-FED). Căn cứ vào đó, tiến hành lập tài liệu đặc tả yêu cầu, phân tách rạch ròi các yêu cầu chức năng (các loại cảnh báo, giao tiếp API) và yêu cầu phi chức năng (FPS tối thiểu, mức tiêu hao tài nguyên, tính ổn định) của toàn bộ hệ thống.
- **Chương 3. Nền tảng lý thuyết và công nghệ sử dụng:** Xây dựng khung lý luận vững chắc cho quá trình lập trình. Giới thiệu cơ sở toán học và phương pháp luận chiết xuất hình học không gian của các chỉ số sinh trắc học EAR, MAR, tiêu chuẩn đo lường mật mỗi PERCLOS. Diễn giải lý thuyết kiến trúc mạng học sâu MobileNetV3 (các khối bottleneck, chiều sâu layer) và phân tích vai trò của các công nghệ phần mềm phụ trợ (Framework PyTorch, môi trường Flask, cơ sở dữ liệu SQLite, và giao thức kết nối SSE).
- **Chương 4. Phân tích thiết kế mô hình và hệ thống:** Thể hiện tư duy kỹ sư phần mềm bằng việc thiết kế bản vẽ kiến trúc. Trình bày chi tiết luồng xử lý (Pipeline) tổng thể qua các lưu đồ thuật toán (Flowcharts). Đặc tả quá trình thiết kế lược đồ cơ sở dữ liệu (Database Schema) trong SQLite, thiết kế các mô-đun tiền xử lý ảnh (CLAHE, tăng cường dữ liệu), cũng như mô hình hóa toán học cho logic ra quyết định cảnh báo và cơ chế Đảo nhiễu (Debounce filter).

- **Chương 5. Xây dựng chương trình, thử nghiệm và đánh giá:** Trình bày nhật ký quá trình thực thi từ mã nguồn lý thuyết đến sản phẩm thực tế. Mô tả quá trình huấn luyện mô hình học sâu (đồ thị Loss/Accuracy), các giải pháp lập trình xử lý đa luồng (Multi-threading), và kỹ thuật lặp bỏ qua khung hình (Skip-frame) để tối ưu hệ thống thiết bị biên. Cung cấp hệ thống bảng biểu, số liệu thực nghiệm đo đạc đánh giá độ chính xác của mô hình và hiệu năng tổng thể của phần mềm (như chỉ số FPS/tiêu thụ điện năng CPU).
- **Chương 6. Kết luận và hướng phát triển:** Đóng gói lại công trình bằng cách tổng kết các kết quả khoa học đã đạt được, tiến hành đối chiếu nghiêm ngặt với các mục tiêu ban đầu trong phiếu giao nhiệm vụ đề án. Trình bày minh bạch các điểm hạn chế còn tồn tại (edge cases, giới hạn điều kiện thiếu sáng cực độ) và mở ra các định hướng nâng cấp đầy hứa hẹn trong tương lai (như tích hợp sâu module DMS vào hệ thống điều khiển phanh tự động của xe tự hành).

CHƯƠNG 2. KHẢO SÁT VÀ PHÂN TÍCH YÊU CẦU

2.1 Khảo sát hiện trạng và các nghiên cứu liên quan

2.1.1 Khảo sát các hệ thống hỗ trợ lái xe an toàn trên thị trường

Hiện nay, trên thị trường thiết bị phụ trợ ô tô và giám sát đội xe đã xuất hiện một số giải pháp giám sát hành trình và cảnh báo tài xế, tiêu biểu có thể kể đến:

1. **Các thiết bị giám sát hành trình GPS thông thường (Hộp đen):** Chỉ ghi nhận thông số cơ học như vận tốc, vị trí xe, thời gian lái xe liên tục. Hệ thống này hoàn toàn không biết tài xế có đang ngủ gật hay tức giận hay không mà chỉ cảnh báo cứng nhắc khi tài xế lái xe liên tục quá 4 giờ theo luật định.
2. **Các hệ thống DMS tích hợp sẵn trên xe hạng sang (e.g., Mercedes-Benz Attention Assist, BMW Driver Assistant):** Sử dụng các camera hồng ngoại đặt tiền tích hợp sâu vào hệ thống điều khiển trung tâm của xe để theo dõi chuyển động mắt. Tuy nhiên, các giải pháp này là công nghệ độc quyền, chi phí cực kỳ đắt đỏ và không thể trang bị đại trà cho các dòng xe phổ thông hoặc xe tải chở hàng hiện nay tại Việt Nam.
3. **Các sản phẩm DMS thương mại lắp ngoài (e.g., Seeing Machines Guardian, Smart Eye):** Có độ chính xác rất cao nhưng đi kèm phí bản quyền phần mềm hàng năm rất lớn, thiết bị phần cứng chuyên dụng phức tạp, gây khó khăn cho các doanh nghiệp vận tải vừa và nhỏ trong nước tiếp cận.

2.1.2 Các nghiên cứu nhận diện diện ngủ gật và trạng thái cảm xúc tài xế

Trong giới nghiên cứu học thuật, bài toán DMS thường được chia thành hai nhánh tiếp cận độc lập:

- **Nhánh tiếp cận dựa trên hình học (Geometric-based):** Sử dụng các mốc khuôn mặt (Landmarks) để tính toán EAR và MAR. Nhánh này có ưu điểm là tốc độ tính toán cực kỳ nhanh, chạy tốt trên CPU yếu, nhưng lại gặp nhược điểm lớn là dễ bị báo động giả khi tài xế nheo mắt cười, chớp mắt nhanh tự nhiên hoặc góc mặt nghiêng. Đồng thời, nó hoàn toàn bỏ qua các biểu cảm cảm xúc (như tức giận hay sợ hãi) vốn ảnh hưởng nghiêm trọng tới hành vi lái xe an toàn.
- **Nhánh tiếp cận dựa trên học sâu (Deep Learning-based):** Đưa toàn bộ ảnh khuôn mặt vào các mạng CNN hoặc ViT (Vision Transformer) để phân loại trực tiếp trạng thái mệt mỏi/cảm xúc. Nhánh này có độ chính xác rất cao nhưng đòi hỏi tài nguyên tính toán cực kỳ lớn (GPU mạnh), tốc độ xử lý trên CPU biên rất chậm (chỉ đạt 3–5 FPS), không thể đáp ứng yêu cầu cảnh báo tức thời

dưới 100ms.

Do đó, đề án đề xuất giải pháp **Hybrid (Lai)**: Sử dụng MediaPipe (hình học) chạy ở 30 FPS để bắt kịp các khoảnh khắc nhắm mắt/ngáp nhanh, kết hợp với MobileNetV3 CNN (học sâu cảm xúc) chạy ở 5 FPS để bổ trợ và hiệu chỉnh kết quả cảnh báo. Sự kết hợp này mang lại hiệu quả vượt trội về mặt tài nguyên và độ chính xác.

2.2 Khảo sát các bộ dữ liệu khuôn mặt phục vụ huấn luyện mô hình

Để xây dựng một bộ phân loại cảm xúc và buồn ngủ có độ tin cậy cao, đề án đã thực hiện khảo sát kỹ lưỡng hai nhóm tập dữ liệu chính:

Bảng 2.1: Khảo sát các bộ dữ liệu khuôn mặt phục vụ huấn luyện mô hình

Tên bộ dữ liệu	Loại dữ liệu	Số lượng mẫu	Đặc trưng môi trường	Vai trò trong D
RAF-DB	Biểu cảm tổng quát	~30,000 ảnh	Ánh sáng tự nhiên, góc mặt đa dạng	Huấn luyện cảm tăng (cảm xúc c
AffectNet	Biểu cảm tổng quát	~450,000 ảnh	Internet, biểu cảm tự nhiên phong phú	Tăng cường độ tính tổng quát CNN
FER-2013	Biểu cảm tổng quát	~35,887 ảnh	Ảnh Grayscale chất lượng thấp (48x48)	Kiểm nghiệm trong điều k mờ/nhiều
UTA-RLDD	Giám sát ngủ gật	240 video clips	Tài xế trong cabin xe, trạng thái buồn ngủ thật	Trích xuất v nghiệm chỉ số thực tế
NTHU DDD	Giám sát ngủ gật	360 video clips	Cabin giả lập, có kính râm, ban đêm	Đánh giá sai số đeo kính hoặc l đêm
MLI-DER	Biểu cảm tài xế	~5,000 ảnh	Tài xế trong xe, cảm xúc tức giận/sợ hãi	Tinh chỉnh (fin các lớp cảm xu tiêu cực

2.2.1 Các bộ dữ liệu biểu cảm tổng quát

Các bộ dữ liệu như **RAF-DB** và **AffectNet** là những nguồn dữ liệu biểu cảm khuôn mặt lớn nhất hiện nay được gán nhãn thủ công bởi các chuyên gia. Tuy nhiên, các bức ảnh này chủ yếu được chụp trong điều kiện ánh sáng studio hoặc ảnh selfie trên Internet, thiếu đi các yếu tố gây nhiễu đặc trưng trong cabin xe như rung lắc cơ học, hướng bóng đổ thay đổi liên tục hoặc tài xế đeo kính. Do đó, các bộ dữ liệu này được sử dụng ở giai đoạn huấn luyện ban đầu (Pre-training) để mô hình học được các đặc trưng biểu cảm cơ bản.

2.2.2 Các bộ dữ liệu chuyên biệt về lái xe

Các bộ dữ liệu chuyên biệt như **NTHU DDD** và **UTA-RLDD** được ghi nhận trực tiếp trong cabin xe hơi. Đặc biệt, NTHU DDD cung cấp nhiều kịch bản rất phức tạp: tài xế đeo kính cận, đeo kính râm đen, lái xe dưới ánh nắng chói chang hoặc hoàn toàn trong đêm tối (chỉ có ánh sáng hồng ngoại). UTA-RLDD cung cấp các video tự nhiên của tài xế ở 3 cấp độ: Tỉnh táo (Alert), Mệt mỏi nhẹ (Low vigilant) và Buồn ngủ nặng (Drowsy). Đây là những nguồn tài nguyên quý giá để trích xuất đặc trưng hình học và kiểm nghiệm độ nhạy của thuật toán PERCLOS kết hợp logic cảm xúc.

2.3 Phân tích yêu cầu chức năng hệ thống

2.3.1 Yêu cầu của bộ phát hiện biểu cảm khuôn mặt và cảnh báo dừng AI

- **Yêu cầu F-C1 (Đọc luồng camera đa luồng):** Đọc liên tục các khung hình từ webcam hoặc camera hành trình mà không làm nghẽn luồng xử lý ảnh.
- **Yêu cầu F-C2 (Định vị và bám sát khuôn mặt):** Phát hiện vùng mặt của tài xế và vẽ hộp bao (bounding box) ổn định, không bị giật hoặc nhảy lệch vị trí khi tài xế di chuyển nhẹ đầu.
- **Yêu cầu F-C3 (Trích xuất chỉ số hình học):** Tính toán chính xác giá trị EAR (hai mắt), MAR (miệng) và góc cúi đầu Pitch từ 468 mốc khuôn mặt FaceMesh.
- **Yêu cầu F-C4 (Phân loại cảm xúc bằng CNN):** Chạy mô hình MobileNetV3 để dự đoán xác suất của 5 trạng thái cảm xúc của tài xế.
- **Yêu cầu F-C5 (Logic quyết định và cảnh báo âm thanh):** Đưa ra kết luận trạng thái cuối cùng (Bình thường, Mệt mỏi, Tức giận, Sợ hãi, Mất tập trung) và phát tiếng Beep cảnh báo ngay lập tức nếu trạng thái tiêu cực vượt ngưỡng.
- **Yêu cầu F-C6 (Gửi telemetry lên Server):** Đóng gói dữ liệu (Mã xe, Tên tài xế, Trạng thái, F-Score, Anger Level, Fear Level, Timestamp) gửi lên Server trung tâm qua HTTP POST.

2.3.2 Yêu cầu của Dashboard giám sát và lưu trữ

- **Yêu cầu F-S1 (Tiếp nhận và lưu trữ SQLite):** Cổng API RESTful nhận cập nhật từ nhiều Client đồng thời và thực hiện ghi nhận thông tin xe vào cơ sở dữ liệu `dms_database.db`.
- **Yêu cầu F-S2 (Lọc nhiễu dữ liệu - Debounce):** Áp dụng bộ lọc thời gian để tránh ghi đè liên tục các log cảnh báo trùng lặp của cùng một xe trong thời gian ngắn (dưới 10 giây).

- **Yêu cầu F-S3 (Quản lý trạng thái kết nối):** Tự động phát hiện và cập nhật trạng thái Online/Offline của các xe (nếu quá 4.0 giây không nhận được tín hiệu check-in từ xe, coi như xe ngoại tuyến).
- **Yêu cầu F-S4 (Đẩy dữ liệu thời gian thực qua SSE):** Thiết lập kết nối luồng SSE (/api/stream) để đẩy trực tiếp dữ liệu thay đổi của các phương tiện xuống Dashboard.
- **Yêu cầu F-S5 (Trực quan hóa Live Monitor):** Hiển thị danh sách xe bên Sidebar, Banner trạng thái lớn, thanh progress thể hiện mức độ mệt mỗi/tức giận/sợ hãi và vẽ biểu đồ đường diễn tiến thời gian thực bằng Chart.js.
- **Yêu cầu F-S6 (Xem lịch sử và tìm kiếm):** Cung cấp giao diện truy vấn bằng SQLite lịch sử cảnh báo có bộ lọc tìm kiếm theo biển số xe và phân loại trạng thái lỗi.
- **Yêu cầu F-S7 (Quản lý hồ sơ tài xế và chấm điểm an toàn):** Hiển thị danh sách hồ sơ lái xe, tự động tổng hợp số lần vi phạm lỗi và tính toán Điểm số An toàn (Safety Score) theo công thức phạt lỗi.

2.4 Phân tích yêu cầu phi chức năng đối với mô hình AI

Bên cạnh các chức năng nghiệp vụ, hệ thống DMS yêu cầu rất khắt khe về các chỉ số phi chức năng (Non-functional Requirements) để đảm bảo có thể hoạt động bền bỉ, an toàn trong môi trường rung lắc và nóng bức của cabin xe:

2.4.1 Yêu cầu về độ chính xác phân loại của mô hình học sâu

- **Độ chính xác tổng thể (Overall Accuracy):** Mô hình phân loại cảm xúc MobileNetV3 phải đạt độ chính xác trên tập dữ liệu kiểm thử (Test set) tối thiểu là 85%.
- **Độ nhạy đối với lớp Tức giận (Recall for Anger):** Phải đạt tối thiểu 80% để tránh bỏ sót các hành vi lái xe bốc đồng nguy hiểm.
- **Tỷ lệ báo động giả (False Positive Rate):** Phải duy trì dưới mức 5% để tránh việc phát tiếng Beep liên tục khi tài xế nói chuyện, nhai kẹo hoặc cười vui vẻ, gây ức chế tâm lý làm tài xế tắt thiết bị.

2.4.2 Yêu cầu về tốc độ xử lý và độ trễ suy luận

- **Tốc độ xử lý khung hình (FPS phía Client):** Hệ thống camera đọc và trích xuất mốc hình học (MediaPipe) phải hoạt động ổn định ở mức từ 25 đến 30 khung hình/giây (FPS) trên CPU phổ thông.
- **Độ trễ suy luận AI (Inference Latency):** Thời gian suy luận của mô hình CNN trên mỗi khung hình phải nhỏ hơn 50ms.

- **Độ trễ phát tín hiệu cảnh báo:** Kể từ thời điểm tài xế nhắm mắt hoặc có góc gục đầu quá ngưỡng, tiếng Beep cảnh báo cục bộ phải phát ra trong vòng 100ms để đảm bảo tính phản ứng tức thời.
- **Độ trễ truyền mạng và hiển thị Dashboard:** Thời gian truyền nhận tín hiệu từ xe lên máy chủ trung tâm và hiển thị lên màn hình điều hành qua luồng SSE phải nhỏ hơn 1.0 giây trong điều kiện kết nối mạng di động (4G/5G) bình thường.
- **Tải nguyên CPU phía Client:** Chương trình AI chạy biên chỉ được phép chiếm dụng tối đa 40% tài nguyên CPU của thiết bị để tránh hiện tượng quá nhiệt (overheating) khi hoạt động liên tục trong xe dưới trời nắng nóng.

CHƯƠNG 3. NỀN TẢNG LÝ THUYẾT VÀ CÔNG NGHỆ SỬ DỤNG

3.1 Tổng quan về mô hình hình học khuôn mặt và các chỉ số sinh học tài xế

3.1.1 Mô hình MediaPipe FaceMesh trích xuất 468 mốc khuôn mặt

MediaPipe FaceMesh là một giải pháp học máy tiên tiến được phát triển bởi Google nhằm ước lượng topo khuôn mặt 3D trong thời gian thực. Mô hình này áp dụng kiến trúc mạng nơ-ron tích chập sâu (CNN) tối ưu hóa cao cho các thiết bị di động và biên. Luồng xử lý của mô hình gồm hai giai đoạn chính:

1. **Detector (BlazeFace):** Định vị nhanh vùng chứa khuôn mặt trên khung hình thô. Bộ định vị này chạy cực kỳ nhanh và hoạt động như một cơ chế kích hoạt (trigger) để chạy bước tiếp theo.
2. **Regressor (FaceMesh Model):** Nhận vùng ảnh khuôn mặt đã cắt từ bước trước để dự đoán trực tiếp tọa độ 3D của 468 điểm mốc (landmarks) tương quan trên khuôn mặt dưới dạng tọa độ thực tế normalized (x, y, z).

Mô hình hồi quy FaceMesh sử dụng cơ chế tích hợp đặc trưng không gian và học sâu có giám sát, được huấn luyện trên một tập dữ liệu khuôn mặt khổng lồ với nhiều biểu cảm, góc nghiêng và điều kiện ánh sáng khác nhau. Nhờ vậy, mô hình đạt độ ổn định rất cao và không yêu cầu phần cứng cảm biến chiều sâu (như LiDAR hay TrueDepth), giúp giảm thiểu tối đa chi phí thiết bị khi triển khai trên ô tô.

3.1.2 Công thức toán học tính tỷ lệ mở mắt EAR và tỷ lệ mở miệng MAR

Để định lượng trạng thái nhắm/mở mắt và ngáp của tài xế, đồ án sử dụng các công thức hình học tính toán khoảng cách Euclidean giữa các điểm mốc tương ứng trên khuôn mặt:

- **Tỷ lệ mở mắt EAR (Eye Aspect Ratio):** Đối với mỗi mắt, EAR được định nghĩa là tỷ số giữa tổng độ dài hai khoảng cách dọc của mắt chia cho hai lần khoảng cách ngang của mắt. Công thức tổng quát:

$$EAR = \frac{||p_2 - p_6|| + ||p_3 - p_5||}{2||p_1 - p_4||}$$

Trong đó, $p_1, p_2, p_3, p_4, p_5, p_6$ lần lượt là tọa độ 3D của các điểm mốc bao quanh một mắt. Hệ thống sử dụng giá trị EAR trung bình của cả hai mắt để đưa ra quyết định:

$$EAR_{\text{mean}} = \frac{EAR_{\text{Left}} + EAR_{\text{Right}}}{2}$$

Trong mã nguồn của LandmarkEngine, các mốc tương đương được ánh xạ từ

cấu trúc MediaPipe FaceMesh:

- Mắt phải (Right Eye): [33, 160, 158, 133, 153, 144]
- Mắt trái (Left Eye): [362, 385, 387, 263, 373, 380]

- **Tỷ lệ mở miệng MAR (Mouth Aspect Ratio):** Để đo độ mở của khuôn miệng tài xế nhằm nhận dạng hành vi ngáp (yawn), MAR được tính theo công thức tương tự bằng cách đo khoảng cách giữa các điểm mốc viền môi trên và viền môi dưới chia cho khoảng cách ngang giữa hai khóe mép:

$$MAR = \frac{||p_{51} - p_{59}|| + ||p_{53} - p_{57}||}{2||p_{49} - p_{55}||}$$

Các mốc tương ứng được lấy từ LandmarkEngine gồm: khóe miệng trái/phải [61, 291], điểm môi trên dọc [37, 267], và điểm môi dưới dọc [84, 314].

- **Ước lượng góc cúi đầu (Pitch):** Để nhận biết hành vi ngủ gật gục đầu hoặc cúi đầu xem điện thoại, LandmarkEngine thiết lập một mô hình hình học 3D chuẩn của khuôn mặt người gồm 6 điểm mốc chính (đầu mũi, cằm, khóe mắt trái/phải, khóe miệng trái/phải). Bằng việc ánh xạ các tọa độ 2D thực tế nhận được từ camera hành trình với mô hình 3D chuẩn này, hệ thống áp dụng thuật toán giải bài toán PnP (Perspective-n-Point) bằng hàm `cv2.solvePnP` của OpenCV để tìm ra ma trận quay R và ma trận dịch chuyển T . Từ ma trận quay R , hệ thống phân tích ra 3 góc Euler: Pitch (cúi/ngẩng đầu), Roll (ngiên đầu sang hai bên) và Yaw (quay đầu sang trái/phải). Trọng tâm giám sát là góc Pitch biểu thị độ cúi đầu sâu (góc Pitch âm).

3.1.3 Chỉ số PERCLOS trong đánh giá rủi ro mệt mỏi

PERCLOS (Percentage of Eye Closure) là tiêu chuẩn vàng trong y học và ngành an toàn giao thông để định lượng mức độ buồn ngủ của tài xế. Chỉ số này đo tỷ lệ phần trăm thời gian mà mắt người lái nhắm từ 80% trở lên trong một khoảng thời gian quan sát xác định (cửa sổ trượt thời gian). Trong đề án, trạng thái nhắm mắt được định nghĩa khi giá trị $EAR < T_{EAR}$ (ngưỡng nhắm mắt mặc định $T_{EAR} = 0.14$). Nếu gọi N là tổng số khung hình trong cửa sổ trượt (mặc định $N = 150$ khung hình, tương đương khoảng 5 giây hoạt động ở tốc độ 30 FPS) và EAR_i là tỷ lệ mở mắt tại khung hình thứ i , công thức PERCLOS được biểu diễn toán học như sau:

$$PERCLOS = \frac{\sum_{i=1}^N \mathbb{I}(EAR_i < T_{EAR})}{N}$$

Trong đó, $\mathbb{I}(\cdot)$ là hàm chỉ thị, nhận giá trị 1 nếu biểu thức đúng và 0 nếu biểu thức sai. Chỉ số PERCLOS nhận giá trị từ 0.0 (mở mắt hoàn toàn suốt cửa sổ thời gian)

đến 1.0 (nhắm mắt hoàn toàn suốt cửa sổ thời gian). Chỉ số PERCLOS vượt mức 0.3 thể hiện trạng thái buồn ngủ cực kỳ nghiêm trọng.

3.2 Tìm hiểu về mạng học sâu CNN MobileNetV3

3.2.1 Kiến trúc MobileNetV3 tối ưu hóa cho thiết bị di động

Mạng MobileNetV3 được thiết kế nhằm mục đích triển khai hiệu quả trên các thiết bị di động và thiết bị nhúng có tài nguyên phần cứng giới hạn. Google đã áp dụng phương pháp kết hợp giữa tìm kiếm kiến trúc mạng tự động (NAS — Network Architecture Search) và thuật toán tối ưu hóa NetAdapt để thiết kế ra cấu trúc mạng nơ-ron tích chập (CNN) tối ưu nhất về cả hiệu năng lẫn kích thước tệp mô hình.

Đồ án lựa chọn biến thể **MobileNetV3-Large** làm mạng backbone chính. So với các kiến trúc CNN truyền thống như VGG-16 hay ResNet-50 có kích thước hàng trăm Megabytes và tốn hàng trăm mili-giây để xử lý một ảnh trên CPU, MobileNetV3-Large chỉ có kích thước khoảng 13MB (ở dạng PyTorch checkpoint) và thời gian suy luận dưới 15ms trên CPU thường, giúp hệ thống hoạt động mượt mà không cần GPU đắt đỏ trên xe.

3.2.2 Khối Inverted Residuals và khối chú ý Squeeze-and-Excitation

Sự vượt trội về mặt hiệu năng của MobileNetV3 đến từ các khối xây dựng cốt lõi sau:

- **Inverted Residuals với Bottleneck Linear:** Trái ngược với các khối Residual thông thường nén số kênh ở giữa, khối Inverted Residual thực hiện mở rộng số lượng kênh đặc trưng trong lớp ẩn bằng một phép tích chập 1×1 (expansion), thực hiện phép tích chập theo chiều sâu (Depthwise Convolution — DWConv) để trích xuất đặc trưng không gian với chi phí tính toán cực thấp, sau đó nén ngược lại số kênh thông qua tích chập 1×1 (projection). Nhờ liên kết tắt (shortcut connection) nối trực tiếp giữa hai đầu có số kênh nhỏ, luồng thông tin và gradient được truyền đi tốt hơn mà vẫn tiết kiệm bộ nhớ.
- **Khối chú ý Squeeze-and-Excitation (SE):** Được tích hợp trực tiếp vào cấu trúc bottleneck để tăng cường chất lượng biểu diễn đặc trưng. Khối SE thực hiện hai bước:
 1. *Squeeze (Ép):* Gom cụm thông tin không gian của các kênh đặc trưng thành một vector đặc trưng kênh duy nhất thông qua phép toán Global Average Pooling.
 2. *Excitation (Kích hoạt):* Sử dụng hai lớp Fully Connected (FC) với hàm kích hoạt Sigmoid để tính toán trọng số quan trọng (attention weights) cho từng kênh màu đặc trưng. Các kênh đặc trưng chứa thông tin hữu ích

về biểu cảm khuôn mặt (như vùng chân mày co lại khi tức giận) sẽ được nhân với trọng số lớn hơn, trong khi các kênh chứa nhiều nền sẽ bị giảm nhẹ.

3.2.3 Hàm kích hoạt Hard-swish và cơ chế học chuyển giao (Transfer Learning)

- **Hàm kích hoạt Hard-swish:** Hàm kích hoạt Swish ($x \cdot \text{sigmoid}(\beta x)$) giúp cải thiện độ chính xác của mạng sâu nhưng tính toán hàm số mũ e^{-x} của Sigmoid rất tốn kém trên thiết bị nhúng. MobileNetV3 thay thế bằng hàm Hard-swish (h-swish) sử dụng hàm tuyến tính từng khúc ReLU6 để xấp xỉ gần đúng:

$$\text{h-swish}(x) = x \cdot \frac{\text{ReLU6}(x + 3)}{6}$$

Trong đó, $\text{ReLU6}(y) = \min(\max(0, y), 6)$. Phép toán này có thể được tối ưu hóa cực tốt ở cấp độ phần cứng nhúng, tăng tốc độ tính toán đáng kể mà không làm giảm độ chính xác của mô hình.

- **Học chuyển giao (Transfer Learning):** Do số lượng ảnh biểu cảm khuôn mặt tự nhiên thu thập được có giới hạn, việc huấn luyện một mạng CNN lớn từ đầu dễ gây ra hiện tượng quá khớp (overfitting). Đồ án sử dụng cơ chế học chuyển giao bằng cách lấy các trọng số (weights) đã được huấn luyện sẵn trên tập dữ liệu ImageNet-1K khổng lồ làm xuất phát điểm. Hệ thống thực hiện tinh chỉnh (fine-tuning) mô hình qua hai giai đoạn huấn luyện chuyên biệt trên tập dữ liệu DMS tích hợp nhằm chuyển đổi tri thức nhận diện vật thể tổng quát sang tri thức phân biệt các sắc thái biểu cảm tinh vi của tài xế.

3.3 Các công nghệ và thư viện phát triển phần mềm

3.3.1 Ngôn ngữ Python, framework PyTorch và thư viện OpenCV

- **Ngôn ngữ Python:** Được lựa chọn làm ngôn ngữ lập trình xuyên suốt dự án từ tiền xử lý dữ liệu, huấn luyện mô hình cho tới cài đặt ứng dụng biên và Server API nhờ hệ sinh thái thư viện AI cực kỳ phong phú.
- **PyTorch Framework:** Cung cấp nền tảng học sâu mạnh mẽ để thiết kế mạng, nạp dữ liệu đa luồng qua DataLoader, định nghĩa hàm mất mát và chạy tối ưu hóa. PyTorch hỗ trợ đồ thị tính toán động, giúp việc gỡ lỗi mô hình trở nên dễ dàng và cho phép xuất mô hình linh hoạt.
- **Thư viện OpenCV (Open Source Computer Vision Library):** Đóng vai trò là thư viện xử lý ảnh chủ đạo ở Client. OpenCV chịu trách nhiệm giao tiếp với camera phần cứng (Webcam), thực hiện trích xuất khung hình ở dạng ma trận ảnh, crop vùng mặt, thực hiện chuyển đổi màu sắc, lọc cân bằng sáng tương

phản bằng CLAHE, và hiển thị giao diện HUD giám sát thời gian thực lên màn hình tài xế.

3.3.2 Thư viện phân tích dữ liệu: Pandas, NumPy, scikit-learn, matplotlib

- **NumPy:** Xử lý các phép toán ma trận đa chiều hiệu năng cao. Mọi khung hình camera và ảnh khuôn mặt đều được biểu diễn và biến đổi dưới dạng các mảng NumPy.
- **Pandas:** Quản lý cấu trúc dữ liệu, đọc ghi tập tin CSV chứa siêu dữ liệu (meta-data) của các bộ dữ liệu khuôn mặt phục vụ tiền xử lý.
- **scikit-learn:** Cung cấp các công cụ kiểm nghiệm mô hình toán học như phân tích ma trận nhầm lẫn (confusion matrix), tính toán các chỉ số Precision, Recall và F1-score để đánh giá chất lượng mô hình sau huấn luyện.
- **matplotlib:** Thư viện vẽ đồ thị trực quan hóa quá trình huấn luyện mô hình (đường cong Loss và Accuracy) và phân bố nhãn dữ liệu.

3.3.3 Flask Web Server, Server-Sent Events (SSE) và SQLite

- **Flask Web Server:** Một micro-framework viết bằng Python cực kỳ nhẹ, hiệu quả và dễ sử dụng. Flask được sử dụng ở trung tâm điều hành để xây dựng các API nhận dữ liệu RESTful JSON từ các xe gửi về và phục vụ trang web Dashboard.
- **Server-Sent Events (SSE):** Thay vì sử dụng giao thức WebSockets phức tạp cần bắt tay hai chiều và tốn tài nguyên kết nối liên tục, hệ thống sử dụng SSE thông qua endpoint `/api/stream`. SSE là một chuẩn kết nối HTTP một chiều cho phép máy chủ Flask tự động đẩy (push) dữ liệu cập nhật trạng thái mới nhất của các xe xuống trình duyệt của người quản lý ngay khi có sự thay đổi. Điều này giúp Dashboard tự động cập nhật thời gian thực với độ trễ tối thiểu mà không cần tải lại trang.
- **SQLite Database:** Hệ quản trị cơ sở dữ liệu quan hệ dạng tệp nhỏ gọn, không cần cài đặt dịch vụ máy chủ phức tạp. SQLite lưu trữ dữ liệu vĩnh viễn cho hệ thống gồm thông tin đăng ký phương tiện và nhật ký cảnh báo chi tiết, đảm bảo tốc độ ghi đọc nhanh chóng và an toàn dữ liệu khi mất điện đột ngột.

CHƯƠNG 4. PHÂN TÍCH THIẾT KẾ, TRIỂN KHAI VÀ ĐÁNH GIÁ HỆ THỐNG

4.1 Sơ đồ tổng thể hệ thống nhận dạng biểu cảm khuôn mặt tài xế lái xe, phát hiện cảm xúc tiêu cực và cảnh báo

Phần này trình bày sơ đồ các thành phần hệ thống và luồng hoạt động theo các quy trình nghiệp vụ của hệ thống.

4.2 Thiết kế Pipeline xử lý tổng thể của hệ thống

4.2.1 Sơ đồ luồng xử lý thời gian thực từ camera hành trình đến bộ cảnh báo tại thiết bị mobile trên xe

Hệ thống DMS Central được thiết kế vận hành theo một Pipeline tuần tự chặt chẽ, tối ưu hóa tối đa khả năng xử lý song song để đạt tốc độ xử lý thời gian thực 30 FPS. Dưới đây là sơ đồ luồng hoạt động tổng thể của hệ thống:

Hình 4.1: Sơ đồ luồng xử lý thời gian thực từ camera hành trình đến bộ cảnh báo

- **Bước 1:** Đọc khung hình từ camera hành trình dạng BGR thông qua đa luồng (Multi-threaded Capture) đưa vào hàng đợi Frame Queue.
- **Bước 2:** Luồng xử lý chính đọc khung hình từ hàng đợi đưa qua LandmarkEngine (MediaPipe FaceMesh) để kiểm tra phát hiện mặt.
- **Bước 3:** Nếu không phát hiện khuôn mặt quá 2.0s, lập tức kích hoạt trạng thái DISTRACTED (mất tập trung).
- **Bước 4:** Nếu phát hiện khuôn mặt, trích xuất Bounding Box và 468 mốc khuôn mặt, chia thành hai nhánh xử lý song song:
 - *Nhánh hình học:* Tính toán EAR, MAR, Pitch và cập nhật vào FatigueMetrics thông qua cửa sổ trượt 150 frames để xác định chỉ số F_{score} (PERCLOS-based).
 - *Nhánh học sâu:* Cắt ảnh khuôn mặt (Face Crop), đưa qua các bước tiền xử lý (Grayscale + CLAHE + Resize 224x224) và chuyển qua mô hình CNN MobileNetV3 phân loại cảm xúc. Xác suất thô ngõ ra được làm mượt qua ProbSmoother (window 5) và MultiEmotionScorer (window 90).
- **Bước 5:** Đưa các kết quả F_{score} , Anger Level và Fear Level vào bộ logic quyết định decide_state để cho ra nhãn trạng thái tài xế cuối cùng.
- **Bước 6:** Nếu phát hiện trạng thái lỗi, phát âm thanh cảnh báo cục bộ qua loa

cabin (winsound) và gửi gói tin JSON lên Flask Server trung tâm qua HTTP POST.

- **Bước 7:** Flask Server nhận gói tin, thực hiện lưu log vào database SQLite (qua bộ lọc Debounce 10s) và phát tín hiệu SSE (Server-Sent Events) để cập nhật thời gian thực lên Dashboard.

4.2.2 Luồng xử lý offline các clip video từ camera tại trung tâm (server)

Hệ thống không chỉ xử lý trực tiếp trên xe (Client) mà còn hỗ trợ khả năng phân tích offline tại máy chủ trung tâm đối với các đoạn video ghi hình được lưu lại từ camera hành trình. Các đoạn video này được tải lên server và đưa qua một Pipeline phân tích chuyên sâu nhằm tái hiện lại trạng thái của tài xế trước thời điểm xảy ra sự cố, phục vụ công tác điều tra và hậu kiểm đánh giá hành vi lái xe.

4.2.3 Mô tả các giai đoạn luân chuyển và biến đổi dữ liệu

Dữ liệu đi qua Pipeline của hệ thống được biến đổi liên tục qua các giai đoạn sau:

1. **Giai đoạn Thu nhận (Input Stage):** Luồng camera đọc luồng video thô từ phần cứng thành một chuỗi các ma trận ảnh BGR kích thước $640 \times 480 \times 3$ trong một luồng (thread) chạy nền độc lập.
2. **Giai đoạn Trích xuất mốc (Landmark Stage):** Ma trận BGR được chuyển sang RGB để đưa vào MediaPipe FaceMesh. Kết quả trả về là một danh sách tọa độ của 468 mốc khuôn mặt và hộp bao khuôn mặt (Bounding Box).
3. **Giai đoạn Tính toán đặc trưng hình học (Geometric Feature Stage):** Tọa độ các điểm mốc được đưa vào công thức toán học để tính ra 3 giá trị vô hướng: *EAR* (float), *MAR* (float), và *Pitch* (float). Các giá trị này được cập nhật liên tục vào danh sách lịch sử của *FatigueMetrics* để tính chỉ số F_{score} (tổng hợp từ PERCLOS, tần suất ngáp và tần suất gật đầu).
4. **Giai đoạn Tiền xử lý & Học sâu (Preprocessing & CNN Stage):** Vùng ảnh chứa khuôn mặt được cắt ra dựa trên Bounding Box, chuyển thành ảnh Grayscale, áp dụng cân bằng histogram CLAHE, resize về kích thước chuẩn $224 \times 224 \times 3$, và chuẩn hóa màu theo ImageNet. Mạng MobileNetV3 thực hiện suy luận để xuất ra vector Logits 5 chiều tương ứng với 5 lớp cảm xúc, sau đó đi qua hàm Softmax để chuyển đổi thành vector xác suất.
5. **Giai đoạn Làm mượt và Quyết định (Smoothing & Decision Stage):** Xác suất cảm xúc thô được đưa qua ProbSmoother và MultiEmotionScorer để tính giá trị trung bình trượt. Bộ logic tích hợp sẽ so khớp các giá trị F_{score} , *AngerLevel*, *FearLevel* với các ngưỡng cảnh báo tương ứng để xác định một

nhân chuỗi duy nhất: NORMAL, FATIGUE, ANGRY, FEAR, hoặc DISTRACTED.

6. **Giai đoạn Truyền thông và Trực quan (Communication Stage):** Nhân trạng thái và các thông số đi kèm được đóng gói thành định dạng JSON và truyền tải qua giao thức HTTP POST lên máy chủ Flask. Máy chủ lọc trùng dữ liệu (Debounce), ghi vào SQLite, và đẩy dữ liệu JSON này xuống Dashboard qua luồng SSE dạng chuỗi văn bản UTF-8 kết nối liên tục.

4.3 Thiết kế chi tiết các khối xử lý và xây dựng bộ dữ liệu

4.3.1 Phương pháp tái cấu trúc và gom nhóm dữ liệu để tối ưu hóa khả năng học của mạng

Do các bộ dữ liệu khuôn mặt và trạng thái lái xe trên thế giới được thu thập từ nhiều nguồn khác nhau với hệ thống gán nhãn không đồng nhất, đồ án đã thiết kế giải pháp tái cấu trúc và gom nhóm dữ liệu. Các nhãn cảm xúc phức tạp hoặc ít liên quan đến hành vi lái xe an toàn như "Ngạc nhiên" (Surprise) và "Ghê tởm" (Disgust) được lược bỏ hoặc gom nhóm để tập trung tối đa năng lực học của mô hình vào 5 lớp cảm xúc cốt lõi:

- 0_Neutral (Bình thường): Gồm các ảnh biểu cảm tự nhiên, thư giãn của tài xế.
- 1_Anger (Tức giận): Tập trung các ảnh tức giận từ RAF-DB, AffectNet và MLI-DER biểu thị sự ức chế, bực bội (Road Rage).
- 2_Fear (Sợ hãi): Tập trung các ảnh thể hiện sự hoảng hốt, sợ hãi khi gặp tình huống va chạm khẩn cấp.
- 3_Happiness (Vui vẻ): Trạng thái tích cực bình thường của tài xế.
- 4_Sadness (Buồn bã): Trạng thái uể oải, buồn ngủ nhẹ, mệt mỏi thể chất.

Quá trình gom nhóm được tự động hóa bằng tập lệnh Python `data_preprocessing.py`, quét qua thư mục gốc của các dataset, ánh xạ mã nhãn tương ứng về 5 thư mục lớp đích để chuẩn bị cho quá trình huấn luyện.

4.3.2 Thiết kế giải pháp phát hiện và bám sát khuôn mặt

Để đảm bảo vùng khuôn mặt được cắt chính xác làm đầu vào cho mô hình CNN, hệ thống tích hợp bộ phát hiện khuôn mặt BlazeFace phiên bản rút gọn (`blaze_face_short_range.tflite`). Mô hình này hoạt động dựa trên các lớp tích chập nhẹ, tối ưu hóa cho bài toán phát hiện khuôn mặt cự ly gần trong cabin xe. Khi tìm thấy khuôn mặt, hệ thống thu nhận tọa độ hộp bao và liên tục bám sát (tracking) khuôn mặt qua từng khung hình. Nếu tọa độ hộp bao bị thay đổi đột ngột hoặc mất nhận diện tạm thời (dưới 2.0 giây) do tài xế quay mặt quá nhanh, hệ thống

sẽ tự động sử dụng vị trí khuôn mặt ở khung hình trước đó để tránh việc gián đoạn khung hình xử lý.

4.3.3 Thiết kế quy trình tiền xử lý ảnh đầu vào

Ảnh khuôn mặt của tài xế trong cabin ô tô thường chịu ảnh hưởng nặng nề bởi sự thay đổi cường độ ánh sáng (ví dụ: nắng chiếu một bên mặt, đi qua đường hầm tối, lái xe ban đêm). Đồ án thiết kế quy trình tiền xử lý ảnh đầu vào chi tiết như sau:

1. **Cắt khuôn mặt với đệm biên (Face Crop with Padding):** Hộp bao từ bộ phát hiện khuôn mặt được mở rộng thêm một khoảng đệm bằng 20% kích thước hộp bao ($\text{pad} = 0.20$). Điều này đảm bảo ảnh cắt không bị mất phần tai, cằm và trán của tài xế khi nghiêng đầu.
2. **Chuyển đổi Grayscale:** Chuyển đổi vùng ảnh cắt từ hệ màu RGB sang Grayscale để triệt tiêu ảnh hưởng của sự thay đổi màu sắc ánh sáng nhân tạo.
3. **Cân bằng Histogram cục bộ (CLAHE):** Áp dụng thuật toán CLAHE (Contrast Limited Adaptive Histogram Equalization) với thông số giới hạn cắt $\text{clipLimit} = 2.0$ và kích thước ô lưới $\text{tileGridSize} = (8, 8)$. CLAHE giúp tăng cường độ tương phản cho các vùng tối của khuôn mặt (như vùng mắt khi tài xế đeo kính hoặc đội mũ) mà không làm cháy sáng các vùng khác.
4. **Nhân bản kênh màu & Resize:** Nhân bản kênh xám vừa xử lý thành 3 kênh xám giống nhau để giữ nguyên định dạng ngõ vào 3 kênh của MobileNetV3, sau đó thay đổi kích thước ảnh về chuẩn 224×224 pixel.
5. **Chuẩn hóa dữ liệu (Normalization):** Áp dụng phép toán chuẩn hóa trừ giá trị trung bình (mean) và chia cho độ lệch chuẩn (std) của ImageNet giúp tăng tốc độ hội tụ của mô hình trong quá trình huấn luyện và suy luận.

4.3.4 Thiết kế các kỹ thuật tăng cường và cân bằng dữ liệu

- **Tăng cường dữ liệu (Data Augmentation):** Nhằm nâng cao khả năng tổng quát hóa của mô hình đối với các tài xế khác nhau và các góc camera khác nhau, đồ án áp dụng chuỗi biến đổi ngẫu nhiên mạnh mẽ trong PyTorch `transforms.Compose` cho tập dữ liệu huấn luyện:
 - `Resize((256, 256))` sau đó `RandomCrop(224)` nhằm tạo ra các biến thể phóng to, thu nhỏ.
 - `RandomHorizontalFlip(p=0.5)` mô phỏng việc đặt camera ở bên trái hoặc bên phải tài xế.
 - `RandomRotation(degrees=8)` mô phỏng trạng thái tài xế nghiêng đầu sang hai bên.

- ColorJitter ngẫu nhiên thay đổi độ sáng, độ tương phản và độ bão hòa.
- RandomPerspective thay đổi phối cảnh góc nhìn khuôn mặt.
- RandomErasing($p=0.02$) ngẫu nhiên xóa đi một vùng ảnh nhỏ để ép mạng nơ-ron học các đặc trưng phân tán của khuôn mặt thay vì chỉ tập trung vào một vùng duy nhất.

- **Cân bằng dữ liệu (Class Balancing):** Do số lượng ảnh của lớp Neutral chiếm đa số tuyệt đối, đề án áp dụng phương pháp gán trọng số lớp nghịch đảo tần suất (Inverse-frequency class weighting) trong hàm mất mát CrossEntropy-Loss. Đặc biệt, để nâng cao độ nhạy đối với hành vi tức giận (lớp gây rủi ro tai nạn cao nhất), đề án tăng cường trọng số của lớp Anger lên gấp 2.5 lần so với công thức cân bằng chuẩn:

$$w_c = \frac{1}{N_c \sum_j \frac{1}{N_j}} \times C$$

Sau đó:

$$w_{\text{Anger}} = w_{\text{Anger}} \times 2.5$$

4.4 Thiết kế triển khai mô hình học sâu CNN MobileNetV3

4.4.1 Thiết kế sơ đồ kiến trúc mạng MobileNetV3 phân loại cảm xúc

Mạng MobileNetV3-Large nguyên bản được thiết kế để phân loại 1000 lớp đối tượng trên tập dữ liệu ImageNet. Để áp dụng cho bài toán nhận diện cảm xúc 5 lớp của tài xế, đề án thay đổi thiết kế của lớp phân loại ở cuối mạng (Classifier Head) như sau:

- **Backbone:** Giữ nguyên toàn bộ các khối tích chập trích xuất đặc trưng sâu (từ Layer 1 đến Layer 15 của MobileNetV3-Large).
- **Classifier Head (Khối phân loại thiết kế mới):** Lấy đầu ra từ lớp Pooling toàn cục (Global Average Pooling) có kích thước kênh là 1280, đi qua khối Sequential gồm:
 1. Lớp tuyến tính (`nn.Linear(in_features, 256)`) để nén số kênh từ 1280 xuống 256.
 2. Hàm kích hoạt phi tuyến (`nn.Hardswish()`) để tăng tính phi tuyến của bộ phân loại.
 3. Lớp chống quá khớp (`nn.Dropout(p=0.3)`) giúp ngắt ngẫu nhiên 30% kết nối của các nơ-ron trong quá trình huấn luyện.
 4. Lớp tuyến tính ngõ ra (`nn.Linear(256, 5)`) để đưa ra điểm số (logits)

của 5 lớp cảm xúc tài xế.

4.4.2 Thiết kế hàm mất mát và bộ tối ưu hóa

- **Hàm mất mát (Loss Function):** Sử dụng hàm mất mát Cross Entropy đa lớp kết hợp với kỹ thuật làm mịn nhãn (Label Smoothing) và trọng số lớp đã thiết kế ở trên:
 - *Phase 1:* Áp dụng Label Smoothing = 0.1 nhằm làm giảm độ tự tin thái quá của mô hình khi backbone bị đóng băng.
 - *Phase 2:* Áp dụng Label Smoothing = 0.05 khi giải phóng backbone để tinh chỉnh sâu, giúp mô hình tập trung vào việc phân biệt các mẫu khó ở biên quyết định.
- **Bộ tối ưu hóa (Optimizer):** Sử dụng thuật toán AdamW (Adam với cơ chế suy giảm trọng số — Weight Decay = $1e-4$) giúp ổn định trọng số mạng và ngăn ngừa overfitting hiệu quả hơn Adam truyền thống.
- **Tốc độ học (Learning Rate) & Bộ điều chỉnh (Scheduler):**
 - *Phase 1 (Backbone frozen):* Thiết lập $lr = 3 \times 10^{-4}$ để huấn luyện nhanh Classifier Head mới.
 - *Phase 2 (Backbone unfrozen):* Thiết lập $lr = 5 \times 10^{-5}$ để tinh chỉnh rất nhẹ các trọng số của backbone mà không làm hỏng tri thức tiền huấn luyện ImageNet.
 - *LR Scheduler:* Áp dụng ReduceLROnPlateau giám sát độ chính xác của tập validation (val_acc). Nếu sau 3 epoch liên tiếp độ chính xác không cải thiện, tốc độ học sẽ giảm đi một nửa (factor = 0.5).

4.5 Thiết kế chi tiết khối quyết định cảnh báo

4.5.1 Thiết kế tập luật logic tích hợp chỉ số hình học và xác suất cảm xúc CNN

Để đảm bảo tính chính xác cao nhất và giảm thiểu tối đa hiện tượng báo động sai gây khó chịu cho người lái, hệ thống thiết kế một tập luật quyết định logic tích hợp có phân cấp độ ưu tiên (Priority Decision Logic):

1. **Mất nhận dạng khuôn mặt (Distracted):** Nếu bộ trích xuất mốc hình học thông báo không tìm thấy khuôn mặt trong khoảng thời gian vượt quá $face_lost_timeout = 2.0$ giây, hệ thống lập tức kết luận trạng thái là DISTRACTED và phát âm thanh cảnh báo.
2. **Mệt mỏi và buồn ngủ (Fatigue):** Nhãn trạng thái có độ ưu tiên cao nhất khi có mặt tài xế. Nếu giá trị $F_{score} > 0.30$, hệ thống lập tức kết luận trạng thái

tài xế là FATIGUE mà không cần xét các chỉ số cảm xúc khác.

3. **Tức giận (ANGRY):** Nếu không buồn ngủ, hệ thống kiểm tra mức độ tức giận tích lũy. Nếu $AngerLevel > 0.25$, hệ thống đưa ra nhãn cảnh báo ANGRY (tài xế đang căng thẳng, tức giận).
4. **Sợ hãi (FEAR):** Nếu không buồn ngủ và không tức giận, kiểm tra mức độ sợ hãi. Nếu $FearLevel > 0.25$, hệ thống đưa ra nhãn cảnh báo FEAR (tài xế đang hoảng loạn, sợ hãi).
5. **Bình thường (NORMAL):** Các trường hợp còn lại được coi là trạng thái lái xe an toàn bình thường.

4.5.2 Thiết kế cơ chế cửa sổ thời gian đảm bảo độ tin cậy cảnh báo

Để tránh việc nháy mắt ngẫu nhiên hoặc cử động mắt bất ngờ gây ra báo động giả (flickering), hệ thống sử dụng các cơ chế lưu vết chuỗi thời gian:

- **Cửa sổ hình học:** Cửa sổ trượt $FATIGUE_WINDOW_SIZE = 150$ khung hình (tương đương 5 giây hoạt động ở tốc độ 30 FPS) lưu trữ chuỗi thời gian của EAR , MAR , và $Pitch$ để tính chỉ số PERCLOS và đếm số lần chớp mắt, ngáp ngủ, gật đầu trong vòng 5 giây gần nhất.
- **Cửa sổ cảm xúc:** Cửa sổ trượt $EMOTION_WINDOW_SIZE = 90$ khung hình (tương đương 3 giây hoạt động) lưu trữ chuỗi giá trị xác suất ngõ ra của CNN để tính giá trị trung bình trượt của $AngerLevel$ và $FearLevel$ trong vòng 3 giây gần nhất.

4.6 Thiết kế kiến trúc phần mềm và cơ sở dữ liệu

4.6.1 Thiết kế kiến trúc sơ đồ luồng dữ liệu

Hệ thống hoạt động theo mô hình Client - Server thông qua giao thức truyền thông HTTP và luồng đẩy dữ liệu SSE:

- **Client-side (Thiết bị biên trên xe):** Chạy mã nguồn xử lý ảnh và suy luận AI thời gian thực. Sau mỗi khung hình xử lý, Client đóng gói thông tin trạng thái thành gói tin JSON và gửi bất đồng bộ (non-blocking thread) lên máy chủ bằng phương thức HTTP POST đến địa chỉ `/api/update`.
- **Server-side (Máy chủ điều hành trung tâm):** Nhận gói tin POST, phân tích dữ liệu, cập nhật bảng SQLite lưu trữ vĩnh viễn, đồng thời đẩy dữ liệu này vào hàng đợi hàng ngang (queue) của luồng SSE.
- **Browser Dashboard (Màn hình giám sát từ xa):** Dashboard giám sát kết nối với máy chủ qua đường dẫn SSE `/api/stream` để nhận dữ liệu đẩy tự động dưới dạng luồng sự kiện (event stream) và cập nhật giao diện hiển thị ngay lập

tức.

4.6.2 Thiết kế mô hình dữ liệu quan hệ SQLite

Cơ sở dữ liệu SQLite được lưu trữ dưới dạng một tệp cơ sở dữ liệu duy nhất `dms_database.db` gồm hai bảng dữ liệu quan hệ chính:

- **Bảng vehicles:** Quản lý danh sách các phương tiện trong hệ thống và thời điểm cuối cùng xe gửi dữ liệu về máy chủ (`last_seen`). Khóa chính là `vehicle_id` (Biển số xe). Các trường dữ liệu gồm: `vehicle_id` (TEXT, PK), `driver_name` (TEXT), `last_seen` (REAL).
- **Bảng warning_logs:** Nhật ký lưu trữ chi tiết các lỗi vi phạm của tài xế. Mỗi bản ghi chứa thông tin về biển số xe, tên tài xế, loại trạng thái lỗi vi phạm, các chỉ số đo lường chi tiết và mốc thời gian xảy ra lỗi. Khóa ngoại `vehicle_id` liên kết trực tiếp với bảng `vehicles`. Các trường gồm: `id` (INTEGER, PK, AUTOINCREMENT), `vehicle_id` (TEXT), `driver_name` (TEXT), `state` (TEXT), `f_score` (REAL), `anger_level` (REAL), `fear_level` (REAL), `timestamp` (REAL).

4.6.3 Thiết kế giao diện Dashboard giám sát tập trung

Dashboard được thiết kế theo giao diện Single-Page App (SPA) hiện đại, sử dụng thanh điều hướng bên trên để chuyển đổi nhanh giữa 3 thẻ tab chức năng chính:

1. **Tab "Live Monitor" (Giám sát trực tuyến):** Hiển thị danh sách tất cả các xe kèm theo biểu tượng trạng thái trực tuyến (Online — màu xanh lá) hoặc ngoại tuyến (Offline — màu xám) ở Sidebar. Panel chính hiển thị thông tin xe đang chọn bao gồm biển số xe, tên tài xế, trạng thái hiện tại (màu sắc thay đổi theo mức độ cảnh báo) và các thanh tiến trình trực quan thể hiện giá trị F_{score} , $AngerLevel$, $FearLevel$. Một biểu đồ đường (Line Chart) được vẽ bởi Chart.js thể hiện diễn tiến của các chỉ số trong vòng 60 giây gần nhất.
2. **Tab "Lịch sử cảnh báo" (History Search):** Cung cấp biểu mẫu tìm kiếm cho phép người quản lý truy vấn nhật ký vi phạm trong cơ sở dữ liệu SQLite. Bộ lọc hỗ trợ tìm kiếm chính xác theo Biển số xe và lọc theo Loại trạng thái lỗi vi phạm. Kết quả được trả về dưới dạng bảng chi tiết có phân trang và hiển thị mốc thời gian rõ ràng.
3. **Tab "Hồ sơ tài xế" (Driver Profiles):** Hiển thị danh sách tổng hợp tất cả các lái xe đã đăng ký trên hệ thống. Đối với mỗi lái xe, hệ thống tự động thống kê tổng số lần vi phạm các lỗi tương ứng và hiển thị điểm số an toàn (Safety Score) kèm theo phân loại xếp hạng an toàn giao thông của tài xế đó.

CHƯƠNG 5. CÁC GIẢI PHÁP VÀ ĐÓNG GÓP NỔI BẬT

5.1 Lập trình và cài đặt ứng dụng

5.1.1 Xây dựng và cài đặt luồng thu nhận hình ảnh đa luồng và trích xuất đặc trưng

Để loại bỏ hiện tượng giật khung hình hiển thị khi luồng xử lý AI gặp quá tải hoặc độ trễ suy luận của mô hình CNN tăng nhẹ, Client áp dụng kỹ thuật lập trình đa luồng (Multi-threading):

- **Thread Camera Reader:** Một luồng riêng được khởi chạy bằng thư viện `threading` trong Python để chuyên tâm đọc các khung hình thô từ thiết bị camera hành trình (`cv2.VideoCapture`) với tốc độ tối đa của phần cứng. Khung hình đọc được đưa vào một hàng đợi (Frame Queue) có kích thước giới hạn để tránh tràn bộ nhớ.
- **Thread Processing (Main Thread):** Luồng xử lý chính liên tục lấy khung hình mới nhất từ hàng đợi ra để xử lý. Nếu hàng đợi có nhiều khung hình cũ, luồng chính sẽ chủ động bỏ qua (skip) để luôn xử lý khung hình thời gian thực mới nhất, triệt tiêu hoàn toàn hiện tượng tích lũy độ trễ hình ảnh.

Sau khi lấy khung hình, luồng chính gọi đối tượng `LandmarkEngine` (sử dụng API của thư viện `MediaPipe Tasks` với mô hình `face_landmarker.task`) để định vị khuôn mặt và trích xuất tọa độ 3D của 468 mốc khuôn mặt, tính toán các chỉ số hình học *EAR*, *MAR*, và góc *Pitch*.

5.1.2 Lập trình quá trình huấn luyện mô hình MobileNetV3 trên PyTorch

Quá trình huấn luyện mô hình được lập trình chi tiết trong tập tin Jupyter Notebook `train_mobilenetv3_dms.ipynb` thông qua hai giai đoạn huấn luyện tuần tự để tối ưu hóa hiệu quả học chuyển giao:

- **Thiết lập ban đầu:** Nạp tập dữ liệu `Unified_DMS_Dataset_v4` đã được chuẩn hóa. Số lượng mẫu huấn luyện của các lớp được đếm tự động để tính toán trọng số nghịch đảo tần suất lớp, đồng thời tăng 2.5 lần trọng số cho lớp Anger (`class_weights[1] *= 2.5`).
- **Giai đoạn 1 (Phase 1 - Đóng băng Backbone):**
 1. Đóng băng toàn bộ các lớp đặc trưng của backbone `MobileNetV3-Large` (`requires_grad_(False)`).
 2. Cài đặt bộ tối ưu hóa `AdamW` cho các tham số của Classifier Head mới

thiết kế với tốc độ học lớn $lr = 3 \times 10^{-4}$ và weight decay = $1e-4$.

3. Sử dụng hàm mất mát CrossEntropyLoss với Label Smoothing = 0.1.
4. Huấn luyện trong 5 epoch đầu tiên để Classifier Head nhanh chóng học cách phân loại cảm xúc từ các đặc trưng thô của ImageNet.

• **Giai đoạn 2 (Phase 2 - Mở băng và Tinh chỉnh toàn diện):**

1. Sau epoch thứ 5, giải phóng tất cả các lớp của backbone (`requires_grad_(True)`).
2. Khởi tạo lại bộ tối ưu hóa AdamW với tốc độ học siêu nhỏ $lr = 5 \times 10^{-5}$ để tinh chỉnh rất nhẹ toàn bộ mạng mà không gây hiện tượng phá hủy các trọng số tốt sẵn có.
3. Cài đặt bộ điều chỉnh tốc độ học ReduceLROnPlateau với `patience = 3` và `factor = 0.5`.
4. Siết chặt Label Smoothing xuống còn 0.05 trong hàm mất mát để ép mô hình tối ưu các biên phân loại tinh vi.
5. Áp dụng cơ chế dừng sớm (Early Stopping) với `patience = 8` để tự động ngắt quá trình huấn luyện khi độ chính xác trên tập Validation không tăng thêm trong 8 epoch liên tiếp, tránh lãng phí tài nguyên tính toán và ngăn ngừa quá khớp.

5.1.3 Cài đặt module logic quyết định cảnh báo và âm thanh cục bộ

Cài đặt trong tập tin mã nguồn `inference_mobilenetv3.py`. Khi nhận trạng thái của tài xế ở khung hình hiện tại được quyết định là một trạng thái lỗi (FATIGUE, ANGRY, FEAR, DISTRACTED), hệ thống sẽ kích hoạt còi cảnh báo:

- Để tránh việc phát âm thanh làm nghẽn luồng xử lý video (gây đứng hình camera), còi cảnh báo được phát bằng cơ chế bất đồng bộ (non-blocking). Trên hệ điều hành Windows, hệ thống sử dụng thư viện `winsound` và gọi hàm với cờ chạy bất đồng bộ: `winsound.PlaySound("SystemHand", winsound.SND_ALIAS | winsound.SND_ASYNC)`
- Để tránh việc âm thanh phát ra liên tục ở mọi khung hình (30 khung hình/giây) gây ức chế tâm lý nghiêm trọng và mất tập trung thêm cho tài xế, hệ thống cài đặt bộ đếm thời gian `cooldown` cảnh báo `BEEP_COOLDOWN = 1.5` giây. Âm thanh bíp tiếp theo chỉ được phép phát ra sau khi đã trôi qua ít nhất 1.5 giây kể từ lần bíp trước đó.

5.1.4 Phát triển Flask Server APIs, database SQLite và giao diện Dashboard

- **Flask Server** (`dashboard_server.py`): Khởi tạo một Flask app lắng nghe ở cổng 5000. Server định nghĩa luồng kết nối SSE bằng cách thiết lập một hàng đợi (Queue) cho mỗi trình duyệt kết nối vào endpoint `/api/stream`. Một luồng phụ liên tục chạy hàm `check_offline_loop` theo chu kỳ 1.0 giây để kiểm tra thời gian cập nhật của các xe; nếu xe nào quá 4.0 giây không gửi dữ liệu, hệ thống tự động đánh dấu xe đó là "offline" và đẩy thông báo trạng thái xuống Dashboard.
- **Ghi nhận Database SQLite**: Khi cổng `/api/update` nhận được dữ liệu từ xe gửi lên, Server sẽ cập nhật bảng `vehicles`. Đồng thời, nếu trạng thái của xe là trạng thái lỗi, hàm `db_add_warning_log` sẽ thực hiện ghi log vào database SQLite.
- **Cơ chế lọc trùng ghi nhận (Debounce)**: Để tránh việc SQLite bị quá tải do ghi nhận liên tiếp hàng trăm log vi phạm giống nhau của cùng một xe trong vài giây, Server thiết lập cơ chế Debounce 10 giây. Nhật ký lỗi chỉ được ghi thêm vào SQLite nếu lỗi mới khác với lỗi trước đó hoặc khoảng thời gian từ lúc ghi lỗi đó lần gần nhất đã vượt quá 10.0 giây.

5.2 Các giải pháp tối ưu và đóng góp nổi bật về thuật toán (Tối ưu hệ thống)

5.2.1 Thuật toán kết hợp Hybrid (Hình học khuôn mặt & Xác suất cảm xúc CNN)

Đóng góp khoa học và thực tiễn lớn nhất của đề án nằm ở việc thiết kế kiến trúc Hybrid (Lai) kết hợp thế mạnh của hai hướng tiếp cận:

- **Phương pháp hình học (MediaPipe FaceMesh)**: Chạy cực kỳ nhanh trên CPU biên, trích xuất mốc hình học chính xác ở tốc độ 30 FPS. Thích hợp để bắt các hành vi sinh học chớp nhoáng như nhắm mắt buồn ngủ hay ngáp miệng.
- **Phương pháp học sâu (MobileNetV3 CNN)**: Có khả năng học các biểu cảm cảm xúc phi tuyến phức tạp từ ảnh thô vùng mặt.

Bằng việc kết hợp hai nhánh này thông qua logic ưu tiên (Priority Logic), hệ thống không chỉ phát hiện chính xác trạng thái ngủ gật mà còn đồng thời nhận dạng được các cảm xúc tức giận và sợ hãi của tài xế. Giải pháp Hybrid giúp giảm tải cho CPU thiết bị biên bằng cách chỉ chạy mô hình CNN học sâu trên vùng mặt đã cắt với tần suất bỏ qua khung hình (skip-frame) thích hợp, trong khi nhánh hình học nhẹ vẫn duy trì giám sát liên tục ở tốc độ cao.

5.2.2 Bộ lọc làm mượt xác suất cảm xúc

Trong thực tế lái xe, hình ảnh khuôn mặt tài xế thu được từ camera thường xuyên bị rung động cơ học hoặc thay đổi ánh sáng đột ngột, dẫn đến việc mô hình CNN dự đoán các xác suất cảm xúc bị dao động mạnh giữa các khung hình kề nhau (flickering). Để khắc phục triệt để lỗi này, đề án đề xuất giải pháp làm mượt hai cấp độ:

1. **Bộ lọc làm mượt xác suất ProbSmoother:** Sử dụng một cửa sổ trượt kích thước nhỏ $W_{\text{smooth}} = 5$ khung hình. Giá trị xác suất cảm xúc đưa vào quyết định trạng thái là trung bình cộng xác suất của 5 khung hình gần nhất:

$$\bar{P}_c(t) = \frac{1}{W_{\text{smooth}}} \sum_{i=0}^{W_{\text{smooth}}-1} P_c(t-i)$$

2. **Bộ tích lũy cảm xúc MultiEmotionScorer:** Để đánh giá đúng trạng thái tâm lý ổn định của tài xế, hệ thống sử dụng một cửa sổ trượt lớn $W_{\text{score}} = 90$ khung hình (tương đương 3 giây hoạt động) để tính toán điểm mức độ cảm xúc tích lũy (Anger/Fear levels). Giá trị mức độ cảm xúc chỉ vượt ngưỡng cảnh báo khi biểu cảm tiêu cực đó được duy trì liên tục hoặc lặp lại với tần suất cao trong suốt 3 giây quan sát.

5.2.3 Cơ chế tự động điều chỉnh ngưỡng động theo đặc trưng sinh học khuôn mặt

Kích thước mắt tự nhiên của mỗi người là khác nhau (ví dụ: người mắt hí, người mắt một mí tự nhiên thường có tỷ lệ EAR lúc mở mắt bình thường rất nhỏ, dễ bị hệ thống nhận nhầm là đang nhắm mắt buồn ngủ). Để khắc phục nhược điểm của các hệ thống DMS sử dụng ngưỡng EAR cố định trên thị trường, đề án thiết kế cơ chế tự động điều chỉnh ngưỡng động (Dynamic Calibration):

- Khi tài xế khởi động hệ thống, trong 5 giây đầu tiên, LandmarkEngine sẽ liên tục thu thập dữ liệu EAR của tài xế trong trạng thái mở mắt bình thường để tính toán giá trị trung bình mở mắt EAR_{open} .
- Hệ thống yêu cầu tài xế nhắm mắt hoàn toàn trong 2 giây để thu thập giá trị trung bình nhắm mắt EAR_{closed} .
- Ngưỡng nhắm mắt động $T_{\text{EAR_dynamic}}$ được tính toán tự động dựa trên khoảng cách sinh học giữa trạng thái mở mắt và nhắm mắt của chính tài xế đó:

$$T_{\text{EAR_dynamic}} = EAR_{\text{closed}} + \alpha \times (EAR_{\text{open}} - EAR_{\text{closed}})$$

Trong đó, hệ số điều chỉnh α được thực nghiệm tối ưu ở mức 0.25.

5.2.4 Thuật toán tự động chấm điểm an toàn

Tại máy chủ trung tâm Flask, hệ thống áp dụng thuật toán tự động chấm điểm an toàn tích lũy cho tài xế (Safety Score) dựa trên lịch sử lỗi vi phạm được ghi nhận trong SQLite. Điểm số an toàn ban đầu của mỗi tài xế khi bắt đầu ca làm việc là 100.0 điểm (thể hiện trạng thái lái xe hoàn hảo). Khi tài xế vi phạm các lỗi cảnh báo và được ghi nhật ký vào database, hệ thống sẽ thực hiện trừ điểm tự động theo công thức phạt lỗi lũy tiến:

$$\text{Safety Score} = \max(0.0, 100.0 - (N_{\text{fatigue}} \times 10.0 + N_{\text{distracted}} \times 8.0 + N_{\text{angry}} \times 5.0 + N_{\text{fear}} \times 3.0))$$

Trong đó:

- N_{fatigue} : Tổng số lần vi phạm lỗi buồn ngủ/mệt mỏi (bị trừ nặng nhất - 10 điểm/lần).
- $N_{\text{distracted}}$: Tổng số lần vi phạm lỗi mất tập trung quay mặt đi nơi khác (trừ 8 điểm/lần).
- N_{angry} : Tổng số lần vi phạm trạng thái tức giận nóng nảy (trừ 5 điểm/lần).
- N_{fear} : Tổng số lần vi phạm trạng thái sợ hãi, hoảng loạn (trừ 3 điểm/lần).

Dựa trên Điểm số An toàn tích lũy cuối ca làm việc, hệ thống thực hiện xếp hạng lái xe:

- $\text{Safety Score} \geq 80.0$: Xếp hạng **Tốt** (Lái xe an toàn).
- $50.0 \leq \text{Safety Score} < 80.0$: Xếp hạng **Trung bình** (Cần nhắc nhở cải thiện hành vi).
- $\text{Safety Score} < 50.0$: Xếp hạng **Nguy hiểm** (Cần đình chỉ ca lái xe để đảm bảo an toàn).

5.3 Thử nghiệm và đánh giá chất lượng mô hình

5.3.1 Đánh giá độ chính xác trên các tập dữ liệu liên quan

Mô hình MobileNetV3-Large sau khi trải qua quá trình huấn luyện 2 giai đoạn trên tập dữ liệu DMS tích hợp v4 đã được kiểm nghiệm độc lập trên tập dữ liệu kiểm thử (Test set) gồm các ảnh khuôn mặt tự nhiên chưa từng xuất hiện trong quá trình huấn luyện (trích xuất từ AffectNet và RAF-DB). Kết quả kiểm nghiệm được thể hiện chi tiết qua bảng dưới đây:

Bảng 5.1: Kết quả đánh giá mô hình MobileNetV3 trên tập kiểm thử

Lớp cảm xúc	Số lượng mẫu	Precision	Recall	F1-Score
0_Neutral	1,250	0.90	0.92	0.91
1_Anger	820	0.85	0.82	0.83
2_Fear	640	0.81	0.78	0.79
3_Happiness	980	0.93	0.95	0.94
4_Sadness	790	0.84	0.83	0.83
Trung bình mẫu (Macro Avg)	4,480	0.86	0.86	0.86
Độ chính xác tổng thể (Accuracy)	4,480	88.4%		

5.3.2 Biểu diễn kết quả huấn luyện

Quá trình huấn luyện mô hình được trực quan hóa qua biểu đồ đường cong tổn thất (Loss Curves) và đường cong độ chính xác (Accuracy Curves) lưu trong tệp `training_curves.png`:

- **Đường cong tổn thất (Loss):** Trong 5 epoch đầu tiên của Phase 1 (backbone frozen), Loss giảm nhanh từ mức 1.52 xuống còn 0.85. Ngay khi bước sang epoch thứ 6 (Phase 2 - unfreeze backbone), Loss có độ dao động nhẹ do thay đổi quy mô smoothing nhân từ 0.1 sang 0.05, sau đó tiếp tục giảm đều đặn và hội tụ ổn định ở mức cực thấp là 0.21 trên tập Train và 0.28 trên tập Validation tại epoch thứ 22.
- **Đường cong độ chính xác (Accuracy):** Độ chính xác trên tập Validation đạt khoảng 76% ở cuối Phase 1. Sau khi mở băng toàn bộ mạng để tinh chỉnh sâu ở Phase 2, độ chính xác tăng trưởng mạnh mẽ và đạt giá trị tốt nhất là 88.4% ở epoch thứ 20 trước khi kích hoạt cơ chế dừng sớm (Early Stopping) ở epoch thứ 28.

5.3.3 Đánh giá độ chính xác qua các chỉ số

Nhận xét kết quả thực nghiệm:

- Lớp Happiness đạt F1-score cao nhất (0.94) do biểu cảm vui vẻ có các đặc trưng cơ mặt rất rõ nét (khóe miệng mở rộng, mắt híp nhẹ) dễ nhận diện.
- Lớp Anger (Tức giận) đạt độ phủ (Recall) khá cao là 82% mặc dù lượng mẫu gốc ít hơn nhiều so với lớp Neutral. Điều này chứng minh hiệu quả vượt trội của kỹ thuật tăng cường trọng số phạt lớp Anger lên 2.5 lần đã thiết kế trong hàm mất mát.
- Ma trận nhầm lẫn (Confusion Matrix) lưu trong tệp `confusion_matrices.png` cho thấy sự nhầm lẫn giữa các lớp cảm xúc tiêu cực (như Anger và Sadness) ở mức rất thấp dưới 4.5%, đảm bảo tính chính xác cao của hệ thống khi đưa ra

các nhãn cảnh báo trạng thái.

5.4 Kịch bản thử nghiệm hệ thống và đánh giá hiệu năng

Đồ án đã thực hiện chạy thực nghiệm tích hợp toàn bộ hệ thống gồm thiết bị camera RGB trên xe, mã nguồn xử lý AI biên (Client) và máy chủ Flask nhận dữ liệu, cập nhật cơ sở dữ liệu SQLite và Dashboard trung tâm thời gian thực. Kết quả đo đạc các chỉ số hiệu năng phi chức năng đạt được như sau:

1. **Tốc độ xử lý khung hình (Client FPS):** Hệ thống duy trì ổn định ở mức **28.2 đến 30.0 FPS** trên thiết bị máy tính văn phòng phổ thông sử dụng CPU Intel Core i5-1135G7 không cần card đồ họa rời GPU. Đây là tốc độ lý tưởng đáp ứng yêu cầu xử lý video mượt mà thời gian thực.
2. **Độ trễ suy luận của mô hình CNN:** Thời gian trích xuất và suy luận mô hình MobileNetV3 trên mỗi khung hình cắt mặt dao động từ **11.2ms đến 14.5ms**, nhỏ hơn rất nhiều so với ngưỡng giới hạn 50ms đặt ra.
3. **Mức độ chiếm dụng tài nguyên CPU:** Luồng xử lý đa luồng tối ưu giúp chương trình Client chỉ chiếm dụng trung bình **24.5% tài nguyên CPU** của thiết bị biên, đảm bảo máy tính không bị quá nhiệt khi chạy liên tục nhiều giờ.
4. **Độ trễ phát âm thanh cảnh báo:** Kể từ thời điểm tài xế nhắm mắt hoặc gục đầu vượt quá ngưỡng cài đặt, âm thanh bíp cảnh báo cục bộ phát ra sau **72ms**, đáp ứng yêu cầu phản xạ tức thời dưới 100ms để tài xế kịp thời tỉnh táo xử lý xe.
5. **Độ trễ truyền mạng và hiển thị Dashboard:** Gói tin telemetry gửi từ xe lên server Flask và hiển thị lên trình duyệt qua SSE mất trung bình **120ms** trong mạng LAN và **280ms** dưới kết nối mạng di động 4G thông thường, vượt xa yêu cầu kỹ thuật dưới 1.0 giây đặt ra.
6. **Tỷ lệ cảnh báo sai thực tế (False Alarm Rate):** Thử nghiệm thực tế với tài xế nói chuyện, cười đùa nhẹ nhàng cho thấy tỷ lệ cảnh báo sai chỉ đạt **3.2%**, tránh gây cảm giác khó chịu ức chế cho người lái xe.

CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1 Kết luận

Sau quá trình nghiên cứu lý thuyết, thiết kế hệ thống và tiến hành thực nghiệm lập trình chi tiết, đồ án đã hoàn thành đầy đủ các mục tiêu và nhiệm vụ đặt ra trong phiếu giao đề tài tốt nghiệp. Các kết quả nổi bật đạt được bao gồm:

1. **Về mặt mô hình AI:** Thiết kế và huấn luyện thành công mô hình học sâu lai (Hybrid) kết hợp tối ưu giữa chỉ số hình học khuôn mặt từ MediaPipe FaceMesh (tính toán EAR, MAR, Pitch để phát hiện ngủ gật, ngáp và mất tập trung) và mô hình CNN MobileNetV3-Large phân loại cảm xúc tiêu cực của tài xế. Mô hình CNN đạt độ chính xác phân loại **88.4%** trên tập dữ liệu kiểm thử thực tế.
2. **Về mặt hệ thống:** Xây dựng hoàn chỉnh giải pháp từ biên lên trung tâm (Edge-to-Cloud). Phía Client trên xe xử lý video đa luồng mượt mà ở tốc độ 30 FPS, phát cảnh báo âm thanh cục bộ bất đồng bộ nhanh chóng dưới 80ms. Phía Server điều hành trung tâm sử dụng Flask Web Server tiếp nhận dữ liệu ổn định, lưu trữ SQLite an toàn với cơ chế lọc trùng debounce 10 giây, và đồng bộ dữ liệu Dashboard thời gian thực thông qua cơ chế Server-Sent Events (SSE).
3. **Về thuật toán tối ưu:** Đề xuất và cài đặt thành công bộ lọc làm mượt xác suất cảm xúc ProbSmoother kết hợp bộ tích lũy cảm xúc MultiEmotionScorer giúp triệt tiêu hiện tượng flickering nhãn cảnh báo; thuật toán tự động hiệu chỉnh ngưỡng EAR động theo sinh học khuôn mặt tài xế; và thuật toán tự động chấm điểm an toàn Safety Score phục vụ đánh giá xếp hạng tài xế chuyên nghiệp.

Hạn chế của hệ thống:

- Hệ thống sử dụng camera ánh sáng thường (RGB) nên hoạt động kém hiệu quả trong điều kiện cabin hoàn toàn tối vào ban đêm nếu không có đèn hồng ngoại phụ trợ.
- Hệ thống chưa nhận diện được các hành vi vi phạm khác như tài xế hút thuốc lá, nghe điện thoại bằng tay hoặc không thắt dây an toàn.

6.2 Hướng phát triển

Để hoàn thiện hệ thống hướng tới thương mại hóa thực tế, các hướng nghiên cứu phát triển tiếp theo bao gồm:

1. **Nâng cấp phần cứng camera:** Tích hợp camera hồng ngoại (IR Camera) kết hợp đèn LED hồng ngoại bước sóng 850nm để hệ thống có khả năng giám sát tài xế ổn định trong mọi điều kiện ánh sáng, kể cả ban đêm hoàn toàn.

2. **Tối ưu hóa mô hình nhúng:** Thực hiện chuyển đổi mô hình PyTorch sang định dạng ONNX hoặc TensorRT, áp dụng các kỹ thuật lượng tử hóa trọng số (Quantization từ FP32 xuống INT8) để giảm thiểu kích thước mô hình và tăng tốc độ suy luận, giúp triển khai mượt mà trên các dòng chip nhúng siêu rẻ như Raspberry Pi 4/5 hoặc Jetson Nano.
3. **Mở rộng tính năng giám sát hành vi:** Phát triển thêm các module AI phát hiện vật thể (như YOLOv8-Pose hoặc YOLOv8-Object) để phát hiện và cảnh báo các hành vi vi phạm khác của tài xế bao gồm: nghe điện thoại bằng tay, hút thuốc lá trong cabin, không thắt dây an toàn hoặc không đặt tay lên vô lăng.
4. **Tích hợp bản đồ và cảnh báo từ xa:** Phát triển thêm tính năng bản đồ số GPS trên Dashboard quản trị trung tâm, hiển thị vị trí thời gian thực của các xe vi phạm lỗi nặng để điều phối viên có thể liên lạc cứu hộ hoặc cảnh báo trực tiếp qua đàm thoại IP kịp thời.

MỘT SỐ LƯU Ý VỀ TÀI LIỆU THAM KHẢO

Lưu ý: Sinh viên không được đưa bài giảng/slide, các trang Wikipedia, hoặc các trang web thông thường làm tài liệu tham khảo.

Một trang web được phép dùng làm tài liệu tham khảo **chỉ khi** nó là công bố chính thống của cá nhân hoặc tổ chức nào đó. Ví dụ, trang web đặc tả ngôn ngữ XML của tổ chức W3C <https://www.w3.org/TR/2008/REC-xml-20081126/> là TLTK hợp lệ.

Có năm loại tài liệu tham khảo mà sinh viên phải tuân thủ đúng quy định về cách thức liệt kê thông tin như sau. Lưu ý: các phần văn bản trong cặp dấu < > dưới đây chỉ là hướng dẫn khai báo cho từng loại tài liệu tham khảo; sinh viên cần xóa các phần văn bản này trong ĐATN của mình.

<**Bài báo đăng trên tạp chí khoa học:** Tên tác giả, tên bài báo, tên tạp chí, volume, từ trang đến trang (nếu có), nhà xuất bản, năm xuất bản >

[1] E. H. Hovy, "Automated discourse generation using discourse structure relations," *Artificial intelligence*, vol. 63, no. 1-2, pp. 341–385, 1993

<**Sách:** Tên tác giả, tên sách, volume (nếu có), lần tái bản (nếu có), nhà xuất bản, năm xuất bản>

[2] L. L. Peterson and B. S. Davie, *Computer networks: a systems approach*. Elsevier, 2007.

[3] N. T. Hải, *Mạng máy tính và các hệ thống mở*. Nhà xuất bản giáo dục, 1999.

<**Tập san Báo cáo Hội nghị Khoa học:** Tên tác giả, tên báo cáo, tên hội nghị, ngày (nếu có), địa điểm hội nghị, năm xuất bản>

[4] M. Poesio and B. Di Eugenio, "Discourse structure and anaphoric accessibility," in *ESSLLI workshop on information structure, discourse structure and discourse semantics*, Copenhagen, Denmark, 2001, pp. 129–143.

<**Đồ án tốt nghiệp, Luận văn Thạc sĩ, Tiến sĩ:** Tên tác giả, tên đồ án/luận văn, loại đồ án/luận văn, tên trường, địa điểm, năm xuất bản>

[5] A. Knott, "A data-driven methodology for motivating a set of coherence relations," Ph.D. dissertation, The University of Edinburgh, UK, 1996.

<**Tài liệu tham khảo từ Internet:** Tên tác giả (nếu có), tựa đề, cơ quan (nếu có), địa chỉ trang web, thời gian lần cuối truy cập trang web>

[6] T. Berners-Lee, *Hypertext transfer protocol (HTTP)*. [Online]. Available: [ft](http://www.w3.org/Protocols/rfc2616/rfc2616-1.html)

p:/info.cern.ch/pub/www/doc/http-spec.txt.Z (visited on 09/30/2010).

[7] Princeton University, *Wordnet*. [Online]. Available: <http://www.cogsci.princeton.edu/~wn/index.shtml> (visited on 09/30/2010).

TÀI LIỆU THAM KHẢO

- [1] E. H. Hovy, “Automated discourse generation using discourse structure relations,” *Artificial intelligence*, vol. 63, no. 1-2, pp. 341–385, 1993.
- [2] L. L. Peterson and B. S. Davie, *Computer networks: a systems approach*. Elsevier, 2007.
- [3] N. T. Hải, *Mạng máy tính và các hệ thống mở*. Nhà xuất bản giáo dục, 1999.
- [4] M. Poesio and B. Di Eugenio, “Discourse structure and anaphoric accessibility,” in *ESSLLI workshop on information structure, discourse structure and discourse semantics, Copenhagen, Denmark*, 2001, pp. 129–143.
- [5] A. Knott, “A data-driven methodology for motivating a set of coherence relations,” Ph.D. dissertation, The University of Edinburgh, UK, 1996.
- [6] T. Berners-Lee, *Hypertext transfer protocol (HTTP)*. Accessed: Sep. 30, 2010. [Online]. Available: <ftp://info.cern.ch/pub/www/doc/http-spec.txt>.
- [7] Princeton University, *Wordnet*. Accessed: Sep. 30, 2010. [Online]. Available: <http://www.cogsci.princeton.edu/~wn/index.shtml>

PHỤ LỤC

A. HƯỚNG DẪN VIẾT ĐỒ ÁN TỐT NGHIỆP

Quy định chung

Dưới đây là một số quy định và hướng dẫn viết đồ án tốt nghiệp mà bắt buộc sinh viên phải đọc kỹ và tuân thủ nghiêm ngặt.

Sinh viên cần đảm bảo tính thống nhất toàn báo cáo (font chữ, căn dòng hai bên, hình ảnh, bảng, margin trang, đánh số trang, v.v.). Để làm được như vậy, sinh viên chỉ cần sử dụng các định dạng theo đúng template ĐATN này. Khi paste nội dung văn bản từ tài liệu khác của mình, sinh viên cần chọn kiểu Copy là “Text Only” để định dạng văn bản của template không bị phá vỡ/vi phạm.

Tuyệt đối cấm sinh viên đạo văn. Sinh viên cần ghi rõ nguồn cho tất cả những gì không tự mình viết/vẽ lên, bao gồm các câu trích dẫn, các hình ảnh, bảng biểu, v.v. Khi bị phát hiện, sinh viên sẽ không được phép bảo vệ ĐATN.

Tất cả các hình vẽ, bảng biểu, công thức, và tài liệu tham khảo trong ĐATN nhất thiết phải được SV giải thích và tham chiếu tối ít nhất một lần. Không chấp nhận các trường hợp sinh viên đưa ra hình ảnh, bảng biểu tùy hứng và không có lời mô tả/giải thích nào.

Sinh viên tuyệt đối không trình bày ĐATN theo kiểu viết ý hoặc gạch đầu dòng. ĐATN không phải là một slide thuyết trình; khi người đọc không hiểu sẽ không có ai giải thích hộ. Sinh viên cần viết thành các đoạn văn và phân tích, diễn giải đầy đủ, rõ ràng. Câu văn cần đúng ngữ pháp, đầy đủ chủ ngữ, vị ngữ và các thành phần câu. Khi thực sự cần liệt kê, sinh viên nên liệt kê theo phong cách khoa học với các ký tự La Mã. Ví dụ, nhiều sinh viên luôn cảm thấy hối hận vì (i) chưa cố gắng hết mình, (ii) chưa sắp xếp thời gian học/chơi một cách hợp lý, (iii) chưa tìm được người yêu để chia sẻ quãng đời sinh viên vất vả, và (iv) viết ĐATN một cách cẩu thả.

Trong một số trường hợp nhất thiết phải dùng các bullet để liệt kê, sinh viên cần thống nhất Style cho toàn bộ các bullet các cấp mà mình sử dụng đến trong báo cáo. Nếu dùng bullet cấp 1 là hình tròn đen, toàn bộ báo cáo cần thống nhất cách dùng như vậy; ví dụ như sau:

- Đây là mục 1 – Thực sự không còn cách nào khác tôi mới dùng đến việc bullet trong báo cáo.
- Đây là mục 2 – Nghĩ lại thì tôi có thể không cần dùng bullet cũng được. Nên tôi sẽ xóa bullet và tổ chức lại hai mục này trong báo cáo của mình cho khoa học hơn. Tôi muốn thầy cô và người đọc cảm nhận được tâm huyết của tôi trong

từng trang báo cáo ĐATN.

A.1 Ngành học

Sinh viên lưu ý viết đúng ngành/chuyên ngành trên bìa và trên gáy theo đúng quy định của Trường. Ngành học hay chuyên ngành học phụ thuộc vào ngành học mà sinh viên đăng ký. Sinh viên có thể đăng nhập trên trang quản lý học tập của mình để xem lại chính xác ngành học của mình.

Một số ví dụ sinh viên có thể tham khảo dưới đây, trong trường hợp có chuyên ngành thì sinh viên không cần ghi chuyên ngành:

- Đối với kỹ sư chính quy:
 - Từ K61 trở về trước: Ngành Kỹ thuật phần mềm
 - Từ K62 trở về sau: Ngành Khoa học máy tính
- Đối với cử nhân:
 - Ngành Công nghệ thông tin
- Đối với chương trình EliteTech:
 - Chương trình Việt Nhật/KSTN: Ngành Công nghệ thông tin
 - Chương trình ICT Global: Ngành Information Technology
 - Chương trình DS&AI: Ngành Khoa học dữ liệu

A.2 Đánh dấu (bullet) và đánh số (numering)


Việc sử dụng danh sách trong LaTeX khá đơn giản và không yêu cầu sinh viên phải thêm bất kỳ gói bổ sung nào. LaTeX cung cấp hai môi trường liệt kê đó là:

- Đánh dấu (bullet) là kiểu liệt kê không có thứ tự. Để sử dụng kiểu liệt kê đánh dấu, chúng ta khai báo như sau

```
\begin{itemize}
\item Nội dung thứ nhất được viết ở đây.
\item Nội dung thứ hai được viết ở đây.
\item ...
\end{itemize}
```

- Đánh số (numering) là kiểu liệt kê có thứ tự. Để sử dụng kiểu liệt kê đánh số, chúng ta khai báo như sau

```
\begin{enumerate}
\item Nội dung thứ nhất được viết ở đây.
\item Nội dung thứ hai được viết ở đây.
\item ...
```



Hình A.1: Internet vạn vật

\end{enumerate}

Chú ý các nội dung trình bày trong cả hai môi trường liệt kê theo sau lệnh `\item`. Ngoài ra LaTeX còn cung cấp một số kiểu liệt kê khác, sinh viên có thể tham khảo tại <https://www.overleaf.com/learn/latex/Lists>

A.3 Cách thêm bảng

Col1	Col2	Col2	Col3
1	6	87837	787
2	7	78	5415
3	545	778	7507
4	545	18744	7560
5	88	788	6344

Bảng A.1: Table to test captions and labels.

Bảng A.1 là ví dụ về cách tạo bảng. Tất cả các bảng biểu phải được đề cập đến trong phần nội dung và phải được phân tích và bình luận. Chú ý: Tạo bảng trong LaTeX khá phức tạp và mất thời gian, vì vậy sinh viên có thể sử dụng các công cụ hỗ trợ tạo bảng (Ví dụ: <https://www.tablesgenerator.com/>). Sinh viên có thể tìm hiểu sâu hơn về cách chèn ảnh trong LaTeX tại link <https://www.overleaf.com/learn/latex/Tables>.

A.4 Chèn hình ảnh

Hình A.1 là ví dụ về cách chèn ảnh. Lưu ý chú thích của hình vẽ được đặt ngay dưới hình vẽ. Sinh viên có thể tìm hiểu sâu hơn về cách chèn ảnh trong LaTeX tại https://www.overleaf.com/learn/latex/Inserting_Images.

Chú ý, tất cả các hình vẽ phải được đề cập đến trong phần nội dung và phải được

phân tích và bình luận.

A.5 Tài liệu tham khảo

Cách liệt kê

Áp dụng cách liệt kê theo quy định của IEEE. Ví dụ của việc trích dẫn như sau **scott2013sdn**. Cụ thể, sinh viên sử dụng lệnh `\cite{}` như sau **ashton2009internet**. Chỉ những tài liệu được trích dẫn thì mới xuất hiện trong phần Tài liệu tham khảo. Tài liệu tham khảo cần có nguồn gốc rõ ràng và phải từ nguồn đáng tin cậy. Hạn chế trích dẫn tài liệu tham khảo từ các website, từ wikipedia.

Các loại tài liệu tham khảo

Các nguồn tài liệu tham khảo chính là sách, bài báo trong các tạp chí, bài báo trong các hội nghị khoa học và các tài liệu tham khảo khác trên internet.

A.6 Cách viết phương trình và công thức toán học

Các gói `amsmath`, `amssymb`, `amsfonts` hỗ trợ viết phương trình/công thức toán học đã được bổ sung sẵn ở phần đầu của file `main.tex`. Một ví dụ về tạo phương trình (A.1) như sau

$$F(x) = \int_b^a \frac{1}{3}x^3 \quad (\text{A.1})$$

Phương trình A.1 là ví dụ về phương trình tích phân. Một phương trình khác không được đánh số thứ tự (gán nhãn)

$$x[t_n] = \frac{1}{\sqrt{N}} \sum_{k=0}^{N-1} X[f_k] e^{j2\pi nk/N}$$

Phương trình này thể hiện phép biến đổi Fourier rời rạc ngược (IDFT).

A.7 Qui cách đóng quyển


Phần bìa trước chế bản theo qui định; bìa trước và bìa sau là giấy liên khổ. Sử dụng keo nhiệt để dán gáy khi đóng quyển thay vì sử dụng băng dính và dập ghim như mô tả ở Hình A.3 Phần gáy ĐATN cần ghi các thông tin tóm tắt sau: Kỳ làm ĐATN - Ngành đào tạo - Họ và tên sinh viên - Mã số sinh viên. Ví dụ:

2022.1 - KỸ THUẬT MÁY TÍNH - NGUYỄN VĂN A - 20221234

Qui cách ghi chữ phần gáy như hình dưới đây:



Hình A.2: Qui cách đóng quyển đồ án



Hình A.3: Qui cách đóng quyển đồ án

B. ĐẶC TẢ USE CASE

Nếu trong nội dung chính không đủ không gian cho các use case khác (ngoài các use case nghiệp vụ chính) thì đặc tả thêm cho các use case đó ở đây.

B.1 Đặc tả use case “Thống kê tình hình mượn sách”

...

B.2 Đặc tả use case “Đăng ký làm thẻ mượn”

...